

UNIVERSIDADE FEDERAL DO RIO GRANDE

Paulo Junior dos Santos Ramiro

**Um comparativo entre Step Forward e
Algoritmo Genético na seleção de características
de indicadores financeiros no mercado de ações**

Brasil

2024

UNIVERSIDADE FEDERAL DO RIO GRANDE

Paulo Junior dos Santos Ramiro

**Um comparativo entre Step Forward e Algoritmo Genético
na seleção de características de indicadores financeiros no
mercado de ações**

Trabalho acadêmico apresentado ao Curso de
Engenharia de Computação da Universidade
Federal do Rio Grande, como requisito par-
cial para a obtenção do grau de Bacharel em
Engenharia de Computação

Orientador: Prof. Dr. Rafael Alceste Berri

Coorientador: Prof. Dr. Giancarlo Lucca

Universidade Federal do Rio Grande – FURG

Centro de Ciências Computacionais

Curso de Engenharia de Computação

Brasil

2024

Este trabalho é dedicado, a todos que:

*Em um fatídico dia,
decidiram parar de somente sonhar
e começaram a correr atrás dos seus sonhos.*

*A todos que rejeitaram o comodismo,
sacrificando-se em prol da construção
de um mundo melhor
para aqueles a quem dedicam seu amor.*

*Por fim,
é dedicado a todos que assustaram
seus próprios monstros.*

*“A menor distância entre
o conhecimento e a ignorância
é a vontade de aprender.”
- Paulo Ramiro.*

Resumo

O Aprendizado de Máquina (AM), junto ao uso de indicadores de análise técnica, tem sido cada vez mais utilizado na previsão de movimentações das ações no mercado financeiro. O objetivo, dessa junção, é criar modelos inteligentes, usando como base indicadores técnicos como Médias Móveis (MM), Convergência-Divergência de Média Móvel (MACD), Índice de Força Relativa (IFR) e outros, capazes de prever o comportamento das ações. Entretanto, para criar modelos eficazes é necessário escolher o conjunto de características (indicadores técnicos) capaz de agregar o máximo de informações relevantes para os algoritmos de aprendizagem de máquina.

O objetivo deste trabalho é estudar o uso de algoritmo evolutivo e de busca sequencial para frente (*Step Forward*), junto ao algoritmo de máquina de vetores de suporte (SVM), na seleção de características de indicadores técnicos. Vale ressaltar que, o estudo é focado na análise das ações da bolsa de valores brasileira (B3 - Brasil, Bolsa, Balcão).

A seleção de características, desse estudo, é voltada para um problema de classificação. Então, para garantir a generalização nas escolhas dos rótulos, foi usada a acurácia junto ao *F1-Score* normalizado, como critério de seleção. Além disso, esse estudo utiliza diferentes valores de hiperparâmetros, do SVM, para realizar os testes de seleção de características.

Palavras-chave: Seleção de Características. Step Forward. Máquinas de Vetores de Suporte. Indicadores financeiros. Análise técnica.

Abstract

Machine Learning (ML), alongside the use of technical analysis indicators, has been increasingly employed in predicting stock movements in the financial market. The goal of this combination is to create intelligent models, utilizing technical indicators such as Moving Averages (MA), Moving Average Convergence Divergence (MACD), Relative Strength Index (RSI), and others as the foundation, capable of forecasting stock behavior. However, to develop effective models, it is crucial to choose a set of features (technical indicators) capable of incorporating the maximum relevant information for machine learning algorithms.

The objective of this work is to investigate the use of evolutionary algorithms and forward sequential search (Step Forward) in conjunction with the Support Vector Machine (SVM) algorithm for selecting features from technical indicators. It is important to note that the study is focused on analyzing stocks in the Brazilian stock market (B3 - Brasil, Bolsa, Balcão).

The feature selection in this study is geared towards a classification problem. To ensure generalization in label choices, accuracy combined with the standardized F1-Score was used as the selection criterion. Additionally, this study employs different hyperparameter values for SVM to conduct feature selection tests.

Keywords: Feature Selection. Step Forward. Support Vector Machines. Financial Indicators. Technical Analysis.

Lista de ilustrações

Figura 1 – Apresentação dos principais termos usados em máquinas de vetores de suportes.	40
Figura 2 – Overview da Metodologia deste Trabalho.	43
Figura 3 – Modelo relacional do banco de dados BovDB.	45
Figura 4 – Exemplo do efeito do evento bonificação na ação PETR4, sem o <i>factor</i> aplicado.	46
Figura 5 – Exemplo do efeito do evento bonificação na ação PETR4, com o <i>factor</i> aplicado.	47
Figura 6 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o canal Linear.	57
Figura 7 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 5 (cinco) dias, para o <i>kernel</i> Linear.	58
Figura 8 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o canal sigmoide.	58
Figura 9 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 5 (cinco) dias, para o <i>kernel</i> Sigmoide.	59
Figura 10 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o canal RBF.	60
Figura 11 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 5 (cinco) dias, para o <i>kernel</i> RBF.	60
Figura 12 – Gráfico com o comportamento da função <i>fitness</i> ao longo do treinamento com os dados da ação VALE3 para um período de 5 (cinco) dias de predição.	63
Figura 13 – Gráficos de acurácia e <i>F1-Score</i> normalizado da empresa VALE3 para predição de 5 (cinco) dias.	63
Figura 14 – Gráfico com o comportamento da função <i>fitness</i> ao longo do treinamento com os dados da ação VALE3 para um período de 15 (quinze) dias de predição.	64
Figura 15 – Gráficos de acurácia e <i>F1-Score</i> normalizado da empresa VALE3 para predição de 15 (quinze) dias.	65
Figura 16 – Gráfico com o comportamento da função <i>fitness</i> ao longo do treinamento com os dados da ação VALE3 para um período de 30 (trinta) dias de predição.	66
Figura 17 – Gráficos de acurácia e <i>F1-Score</i> normalizado da empresa VALE3 para predição de 30 (trinta) dias.	66

Figura 18 – Gráfico com o comportamento da função <i>fitness</i> ao longo do treinamento com os dados da ação PETR4 para um período de 5 (cinco) dias de predição.	67
Figura 19 – Gráficos de acurácia e <i>F1-Score</i> normalizado da empresa PETR4 para predição de 5 (cinco) dias.	67
Figura 20 – Gráfico com o comportamento da função <i>fitness</i> ao longo do treinamento com os dados da ação PETR4 para um período de 15 (quinze) dias de predição.	68
Figura 21 – Gráficos de acurácia e <i>F1-Score</i> normalizado da empresa PETR4 para predição de 15 (quinze) dias.	68
Figura 22 – Gráfico com o comportamento da função <i>fitness</i> ao longo do treinamento com os dados da ação PETR4 para um período de 30 (trinta) dias de predição.	69
Figura 23 – Gráficos de acurácia e <i>F1-Score</i> normalizado da empresa PETR4 para predição de 30 (trinta) dias.	69
Figura 24 – Gráfico com o comportamento da função <i>fitness</i> ao longo do treinamento com os dados da ação ITSA4 para um período de 5 (cinco) dias de predição.	70
Figura 25 – Gráficos de acurácia e <i>F1-Score</i> normalizado da empresa ITSA4 para predição de 5 (cinco) dias.	70
Figura 26 – Gráfico com o comportamento da função <i>fitness</i> ao longo do treinamento com os dados da ação ITSA4 para um período de 15 (quinze) dias de predição.	71
Figura 27 – Gráficos de acurácia e <i>F1-Score</i> normalizado da empresa ITSA4 para predição de 15 (quinze) dias.	71
Figura 28 – Gráfico com o comportamento da função <i>fitness</i> ao longo do treinamento com os dados da ação ITSA4 para um período de 30 (trinta) dias de predição.	72
Figura 29 – Gráficos de acurácia e <i>F1-Score</i> normalizado da empresa ITSA4 para predição de 30 (trinta) dias.	72
Figura 30 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o papel VALE3 para uma previsão de 5 dias.	73
Figura 31 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 5 (cinco) dias com os hiperparâmetros ajustados pelo GA.	73
Figura 32 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o papel VALE3 para uma previsão de 15 dias.	74

Figura 33 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 15 (quinze) dias com os hiperparametros ajustados pelo GA.	74
Figura 34 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o papel VALE3 para uma previsão de 30 dias.	75
Figura 35 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 30 (trinta) dias com os hiperparametros ajustados pelo GA.	75
Figura 36 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o papel PETR4 para uma previsão de 5 dias.	76
Figura 37 – Matriz de confusão, do conjunto de dados de testes, da ação PETR4 com predição de 5 (cinco) dias com os hiperparametros ajustados pelo GA.	76
Figura 38 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o papel PETR4 para uma previsão de 15 dias.	77
Figura 39 – Matriz de confusão, do conjunto de dados de testes, da ação PETR4 com predição de 15 (quinze) dias com os hiperparametros ajustados pelo GA.	77
Figura 40 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o papel PETR4 para uma previsão de 30 dias.	78
Figura 41 – Matriz de confusão, do conjunto de dados de testes, da ação PETR4 com predição de 30 (trinta) dias com os hiperparametros ajustados pelo GA.	78
Figura 42 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o papel ITSA4 para uma previsão de 5 (cinco) dias.	79
Figura 43 – Matriz de confusão, do conjunto de dados de testes, da ação ITSA4 com predição de 5 (cinco) dias com os hiperparametros ajustados pelo GA.	79
Figura 44 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o papel ITSA4 para uma previsão de 15 dias.	80
Figura 45 – Matriz de confusão, do conjunto de dados de testes, da ação ITSA4 com predição de 15 (quinze) dias com os hiperparametros ajustados pelo GA.	80

Figura 46 – Gráficos mostrando os respectivos resultados do <i>F1-Score</i> normalizado e da acurácia, ao longo de cada rodada, para o papel ITSA4 para uma previsão de 30 dias.	81
Figura 47 – Matriz de confusão, do conjunto de dados de testes, da ação ITSA4 com predição de 30 (trinta) dias com os hiperparametros ajustados pelo GA.	81

Lista de tabelas

Tabela 1 – Comparação de vantagens e desvantagens de cada método de seleção de características.	28
Tabela 2 – Informações sobre as tabelas do banco de dados BovDB.	45
Tabela 3 – Relação dos rótulos com a janela histórica de predição.	48
Tabela 4 – Indicadores técnicos que serão utilizado na seleção de características. .	50
Tabela 5 – Ações e rótulos escolhidos para serem estudados.	56
Tabela 6 – Hiperparâmetros usados no algoritmo SVM para realização dos testes de seleção de características.	57
Tabela 7 – Valores dos parâmetros e critérios de paradas do Algoritmos Genético.	61
Tabela 8 – Relação entre ação, rótulos e hiperparâmetros escolhidos na seleção de características utilizando GA.	62
Tabela 9 – Os 20 melhores indicadores de análise técnica para cada método de seleção de características.	83
Tabela 10 – Os 20 piores indicadores de análise técnica para cada método de seleção de características.	83
Tabela 11 – Relação completa, comparando todos os métodos estudados com os indicadores gerados para estudo, com ordenação começando do indicador mais escolhido para o menos escolhido.	93
Tabela 12 – Relação completa entre a seleção de características, usando algoritmo genético, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.	99
Tabela 13 – Relação completa entre a seleção de características, usando <i>Step-Forward</i> com hiperparâmetros ajustados, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.	105
Tabela 14 – Relação completa entre a seleção de características, usando <i>Step-Forward</i> sem ajuste de hiperparâmetros, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.	111
Tabela 15 – Ações listadas no índice IBrX-50.	119

Lista de símbolos

$\sqrt{}$	Símbolo de radiciação
Σ	Símbolo de somatório
μ	Letra grega minúscula Mi
α	Letra grega minúscula alpha
γ	Letra grega minúscula gamma
$\ \cdot\ $	Símbolo de norma euclidiana

Sumário

1	INTRODUÇÃO	23
1.1	Objetivos	24
1.1.1	Objetivo Geral	24
1.1.2	Objetivos específicos	24
1.2	Organização do trabalho	25
2	FUNDAMENTAÇÃO TEÓRICA	27
2.1	Aprendizado de máquina	27
2.2	Seleção de Características	27
2.2.1	Métodos de Filtragens	29
2.2.1.1	Correlação de Pearson	30
2.2.1.2	Análise de variância (ANOVA)	30
2.2.1.3	Teste t	31
2.2.1.4	Qui-quadrado	32
2.2.1.5	Informação Mútua (MI)	32
2.2.2	Métodos Embutidos	33
2.2.2.1	Regularização Lasso	33
2.2.2.2	Árvores de decisão	33
2.2.2.3	Floresta aleatória	33
2.2.3	Métodos por Envoltórios	34
2.2.3.1	Busca exaustiva	34
2.2.3.2	Busca heurísticas	35
2.2.4	Algoritmos Genéricos	35
2.2.5	Algoritmos de seleção sequencial	36
2.2.5.1	Busca Sequencial para Frente	37
2.2.5.2	Busca Sequencial para Trás	37
2.3	Métricas de validação	37
2.3.1	Acurácia	38
2.3.2	Revocação	38
2.3.3	Precisão	38
2.3.4	F1-Score	39
2.4	Máquina de vetores de suporte (SVM)	39
2.4.1	SVM binário vs. SVM multiclasse	40
2.4.2	Hiperparâmetros do SVM estudados nesse Trabalho	41
2.4.3	Funções de canais utilizadas no trabalho	42

3	METODOLOGIA	43
3.1	Dados	43
3.1.1	BovDB	44
3.1.2	Fator (<i>factor</i>)	46
3.2	Definindo rótulos de predição	47
3.3	Definindo indicadores de análise técnica	49
3.4	Abordagens adotadas	51
4	RESULTADOS	55
4.1	Tratamento, processamento e organização dos dados	55
4.2	<i>Step Forward</i> sem ajuste de hiperparâmetros	56
4.3	Seleção de características e ajuste de hiperparâmetros utilizando Algoritmos Genéticos	61
4.4	<i>Step Forward</i> com os hiperparâmetros ajustados	70
4.5	Análises comparativas e discussões	82
5	CONCLUSÃO	85
	REFERÊNCIAS	87
	APÊNDICES	91
	APÊNDICE A – TABELA COMPLETA COMPARANDO TODOS OS INDICADORES TÉCNICOS COM TODAS AS SELEÇÕES DE CARACTERÍSTICAS REALIZADAS	93
	APÊNDICE B – TABELA COMPLETA DE INDICADORES TÉCNICOS SELECIONADOS, USANDO ALGORITMO GENÉTICO COMO SELETOR DE CARACTERÍSTICAS	99
	APÊNDICE C – TABELA COMPLETA COM OS INDICADORES TÉCNICOS SELECIONADOS, USANDO <i>STEP-FORWARD</i> COM HIPERPARÂMETROS AJUSTADOS	105
	APÊNDICE D – TABELA COMPLETA COM OS INDICADORES TÉCNICOS SELECIONADOS, USANDO <i>STEP-FORWARD</i> SEM AJUSTE DE HIPERPARÂMETRO	111

ANEXOS	117
---------------	------------

ANEXO A – TABELA AÇÕES DO ÍNDICE IBRX-50, EXTRAÍDAS NO DIA 16 DE FEVEREIRO DE 2022	119
---	------------

1 Introdução

As bolsas de valores são instituições financeiras que permitem a compra e venda de ações, títulos e outros ativos financeiros (CARDOSO et al., 2022). Elas servem como um mercado secundário, onde investidores compram e vendem ativos, em vez de investir diretamente nas empresas ou governos que emitem esses títulos.

A história da bolsa de valores remonta ao século XVII, quando os comerciantes holandeses começaram a negociar ações de companhias comerciais no café Beurs van Hendrick de Vries, em Amsterdã. Logo, a primeira bolsa de valores organizada foi fundada em 1720, também na Holanda (PETRAM, 2014). Desde então, as bolsas de valores se espalharam pelo mundo e tornaram-se uma parte importante da economia global.

No Brasil, a principal bolsa de valores é a B3 - Brasil, Bolsa, Balcão¹. Ela foi fundada em 1890 como a Bolsa Livre de Valores de São Paulo, e em 1907 uniu-se à Bolsa de Valores do Rio de Janeiro, tornando-se a Bolsa de Valores do Rio de Janeiro e São Paulo. Em 2000, mudou seu nome para BM&F Bovespa e, em 2017, incorporou a Companhia Brasileira de Liquidação e Custódia (Cetip), tornando-se a B3².

A B3 é responsável por intermediar negociações de ações, títulos públicos e outros ativos financeiros. Ela desempenha um papel fundamental na economia brasileira, promovendo a captação de recursos para as empresas e facilitando a alocação de capital para investimentos.

Como dito, as bolsas de valores gerenciam as movimentações de ativos financeiros. Cabe destacar que, são considerados ativos financeiros os bens que são capazes de gerar algum valor econômico e incluem ações, títulos de dívida, fundos imobiliários, moedas estrangeiras e outros instrumentos financeiros (JARROW; PROTTER, 2007).

Ações são títulos financeiros que representam uma fração de propriedade em uma empresa (WANG, 2021). Devido ao valor econômico dos ativos financeiros, há uma série de estudos que buscam encontrar padrões em suas movimentações e em especial nas movimentações de ações. Dito isso, (MOBILIÁRIOS, 2017) destaca que existem duas principais formas de análise de ativos financeiros que são: a análise técnica e a análise fundamentalista.

A análise fundamentalista se concentra nas informações fundamentais de uma empresa, como sua posição financeira, lucros e receitas, crescimento de mercado e perspectivas de futuro. Os analistas fundamentalistas buscam avaliar o valor intrínseco de uma empresa para determinar se suas ações estão subavaliadas ou sobrevalorizadas (BARROS, 2015).

¹ Link de acesso ao site principal da B3: <https://www.b3.com.br/pt_br>.

² Link de acesso ao site que conta a história da B3: <<https://www.acervob3.com.br/historia-da-bolsa>>.

Já a análise técnica se concentra nas tendências do preço e volume das ações de uma empresa, utilizando gráficos e outras ferramentas para identificar padrões e tendências no mercado. Os analistas técnicos não se preocupam com as informações fundamentais da empresa, mas sim com o comportamento do mercado e como ele pode afetar o preço das ações (BARROS, 2015).

Os inícios dos estudos sobre análise técnica remontam ao século XIX, quando os primeiros gráficos de preços foram utilizados para analisar o comportamento do mercado. Um dos precursores da análise técnica moderna foi Charles Dow, que fundou o Dow Jones & Company e desenvolveu o Índice Dow Jones Industrial Average. Ele foi um dos primeiros a usar gráficos de preços para identificar tendências no mercado e desenvolveu conceitos como tendências de alta e baixa (JR, 1961).

Desde então, os aprofundamentos nos estudos de técnicas analíticas do mercado financeiro proporcionaram uma quantidade considerável de indicadores de análise técnica. Proporcionando, assim, recursos para o uso de inteligência artificial e aprendizado de máquina (MITCHELL; MITCHELL, 1997) voltados à análise do mercado financeiro. Bem como, a necessidade de selecionar combinações de indicadores que sejam eficientes ao treinar modelos de inteligência artificial.

1.1 Objetivos

1.1.1 Objetivo Geral

O objetivo geral deste trabalho é realizar um estudo de seleção de indicadores técnicos que possam ser usados em algoritmos de inteligência artificial. Com isso, prever as movimentações das ações e identificar os movimentos de subida, subida acentuada, decida, decida acentuada e estabilidade.

1.1.2 Objetivos específicos

- Analisar o uso de máquina de vetores de suporte, com diferentes valores de hiperparâmetros, junto aos algoritmos *Step Forward* e algoritmo genético para a seleção de indicadores técnicos;
- Propor os métodos como parte do pré-processamento dos dados para criação de modelos, voltados à predição do mercado financeiro, mais eficientes;
- Eleger a melhor escolha de algoritmo de seleção de características que resolva o objetivo geral (Seção 1.1.1).

1.2 Organização do trabalho

Este trabalho está organizado da seguinte maneira. No Capítulo 2 são apresentadas as terminologias necessárias para a compreensão do trabalho. No Capítulo 3 é apresentada a metodologia adotada nesse trabalho. No Capítulo 4 são apresentados os resultados obtidos. E, por fim, as considerações finais são apresentadas no Capítulo 5.

2 Fundamentação teórica

Neste capítulo são apresentadas as fundamentações teóricas importantes para a compreensão do trabalho, sendo apresentada na Seção 2.1 conceitos sobre aprendizado de máquina. Na Seção 2.2 o tema seleção de características é contextualizado. Já nas Seções 2.3 e 2.4 são explicados, respectivamente, os conceitos de métricas de validação e máquinas de vetores de suporte.

2.1 Aprendizado de máquina

Aprendizado de máquina (ML, do inglês *machine learning*) é uma subárea da inteligência artificial que se concentra no desenvolvimento de algoritmos e técnicas que permitem que as máquinas aprendam automaticamente a partir de dados e melhorem suas habilidades sem serem explicitamente programadas. O objetivo é que as máquinas possam aprender com a experiência e se tornem capazes de realizar tarefas específicas sem a necessidade de serem diretamente controladas por um programador humano (MITCHELL; MITCHELL, 1997).

2.2 Seleção de Características

A seleção de características (em inglês, *feature selection*) é um processo importante no aprendizado de máquina que tem como objetivo identificar e selecionar as características mais relevantes para o modelo. Sua aplicação é importante, pois pode melhorar a precisão e o desempenho do modelo, além de reduzir o tempo de treinamento e a complexidade computacional (CHANDRASHEKAR; SAHIN, 2014).

Um princípio importante é que, quando se trata de aprendizado de máquina, as características são os recursos ou atributos que representam o objeto ou o evento que está sendo classificado ou previsto. Por exemplo, ao se trabalhar com uma tarefa de classificação de imagens, as características podem ser a cor, a forma e o tamanho dos objetos na imagem (CAELLI; REYE, 1993). Porém, se o objetivo for trabalhar com uma tarefa de previsão de séries temporais, como é o caso desse estudo, as características podem ser os preços, volumes ou indicadores de tendências de ativos financeiros.

No entanto, nem todas as características são igualmente importantes ou relevantes para o modelo. Algumas características podem ser redundantes ou irrelevantes para a tarefa, o que pode levar a um modelo menos preciso e mais lento. Por isso, é importante realizar uma seleção cuidadosa das características antes de treinar o modelo (LI et al.,

2017).

Segundo (CHANDRASHEKAR; SAHIN, 2014), (VENKATESH; ANURADHA, 2019) e outros autores, existem três principais categorias de seleção de características: filtragem, envoltório e seleção de recursos embutidos. Essas categorias serão brevemente apresentadas a seguir e mais bem explicadas nas próximas subseções. Sendo elas:

Filtragem (*Filter method*): A filtragem é um processo no qual as características são selecionadas com base em algum critério pré-definido, como correlação com a variável alvo ou teste de hipóteses estatísticas.

Seleção de recursos embutidos (*Embedded method*): A seleção de recursos embutidos é um processo no qual o próprio modelo de aprendizado de máquina é usado para selecionar as características mais relevantes.

Envoltório (*Wrapper method*): O envoltório é um processo no qual as características são selecionadas com base no desempenho de um modelo de aprendizado de máquina.

Na Tabela 1 é possível observar algumas das vantagens e desvantagens de cada categoria de métodos abordados.

Tabela 1 – Comparação de vantagens e desvantagens de cada método de seleção de características.

(Continua)		
Métodos de seleção de características	Vantagens	Desvantagens
Método de Filtragem	– Indepe de algoritmos de aprendizagem de máquinas, sendo genéricos. – Computacionalmente mais rápido que os outros métodos de envoltórios e embutidos. – Adequado para dados de baixa dimensão.	– Não considera a correlação entre os classificadores. – Não considera a correlação entre as características. – Falha em reconhecer os padrões adequadamente durante a fase de aprendizagem.

Tabela 1 – Comparação de vantagens e desvantagens de cada método de seleção de características.

(Continua)

Métodos de seleção de características	Vantagens	Desvantagens
Método de Envoltório	– Considera a correlação entre as características e os rótulos de classe. – Considera as dependências entre as características. – Mais preciso que o método de filtragem.	– Computacionalmente mais complexo. – Avalia iterativamente o subconjunto de recursos selecionado. – Alguns recursos podem não ser considerados para avaliação quando descartados no estágio inicial, mesmo sendo relevantes. – Pode ocorrer overfitting (excesso de aprendizagem) no treinamento, invalidando a seleção de características feita.
Método Embutido	– Computacionalmente mais eficiente do que o método de envoltório. – Mais preciso do que os métodos de filtragem e envoltório.	– Computacionalmente menos eficiente do que o método de filtro. – Não é adequado para dados com alta dimensionalidade. – Com baixa generalização de seleção de característica, com a seleção altamente relacionada com o algoritmo de seleção escolhido.

(Concluído)

Fonte: Baseado em [Venkatesh e Anuradha \(2019\)](#).

2.2.1 Métodos de Filtragens

A técnica de filtragem de características é uma categoria de seleção de características que utiliza medidas estatísticas para avaliar a importância de cada característica em

relação ao problema de classificação ou regressão que está sendo tratado. Sendo que, as características mais relevantes são selecionadas para serem utilizadas no modelo de aprendizado de máquina, enquanto as menos relevantes são descartadas (CHANDRASHEKAR; SAHIN, 2014).

Segundo (VENKATESH; ANURADHA, 2019), a principal vantagem dos métodos de filtragens é que eles conseguem realizar seleções de características com um menor custo computacional, se comparado com as demais técnicas que serão apresentados neste trabalho, como pode ser observado na Tabela 1. Nas subseções a seguir serão apresentadas algumas das técnicas de seleção de características por filtragens mais comuns.

2.2.1.1 Correlação de Pearson

Esta técnica mede a força e a direção da relação linear entre duas variáveis. Uma correlação de Pearson próxima de 1 indica uma forte relação positiva linear, enquanto uma correlação próxima de -1 indica uma forte relação negativa linear. As características com uma correlação muito próxima de 0 são consideradas não relevantes. A fórmula da correlação de Pearson é dada por (ZOU; TUNCALI; SILVERMAN, 2003):

$$r = \frac{\sum (x_i - \bar{x}) (y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \quad (2.1)$$

Onde x e y são as duas variáveis sendo comparadas, $\bar{x}$ e $\bar{y}$ são as médias das respectivas variáveis, e $\sum$ representa a soma.

O valor de r varia de -1 a 1, onde:

- $r = 1$ indica uma forte relação positiva linear (à medida que x aumenta, y também aumenta de forma proporcional);
- $r = -1$ indica uma forte relação negativa linear (à medida que x aumenta, y diminui de forma proporcional);
- $r = 0$ indica ausência de qualquer relação linear (não há qualquer tendência para y aumentar ou diminuir à medida que x aumenta).

2.2.1.2 Análise de variância (ANOVA)

Análise de variância (ANOVA) é uma técnica estatística utilizada para comparar a média de uma variável em diferentes grupos (ST; WOLD et al., 1989). A ideia por trás da ANOVA é a de dividir a variância total dos dados em duas partes: a variância entre os grupos e a variância dentro dos grupos.

A variância entre os grupos é a diferença na média dos grupos, enquanto a variância dentro dos grupos é a variação dentro de cada grupo. Se a diferença entre as médias dos

grupos é grande em comparação com a variação dentro dos grupos, isso indica que a variável independente (o grupo) está tendo um efeito significativo na variável dependente.

A fórmula da ANOVA é dada por (ST; WOLD et al., 1989):

$$F = \frac{\frac{(SST-SSE)}{df_1}}{\frac{SSE}{df_2}} \quad (2.2)$$

Onde SST é a soma total dos quadrados, SSE é a soma dos quadrados residuais, df1 é o número de graus de liberdade do modelo, e df2 é o número de graus de liberdade da aleatoriedade. Para calcular SST, primeiramente é necessário calcular a média total dos dados (todos os grupos juntos). Em seguida, a soma total dos quadrados é dada por (ST; WOLD et al., 1989):

$$SST = \sum(Y_i - \bar{Y})^2 \quad (2.3)$$

Onde Y é a variável dependente e $\bar{Y}$ é a média total dos dados. Para calcular SSE, primeiramente é necessário calcular a média de cada grupo. Em seguida, a soma dos quadrados residuais é dada por (ST; WOLD et al., 1989):

$$SSE = \sum(Y_i - \bar{Y}_i)^2 \quad (2.4)$$

Onde $\bar{Y}_i$ é a média do i-ésimo grupo. O valor de F é então comparado a uma tabela de valores críticos para verificar se é estatisticamente significativo. Se o valor de F for maior que o valor crítico, isso indica que a variável independente está tendo um efeito significativo na variável dependente.

2.2.1.3 Teste t

O Teste t é utilizado para comparar a média de uma variável em dois grupos. Existem dois tipos principais de teste T: o teste T de uma amostra e o teste T de duas amostras. O teste T de uma amostra é utilizado quando se tem apenas uma amostra e se deseja comparar a média dessa amostra com a média da população. Já o teste T de duas amostras é utilizado quando se tem duas amostras e se deseja comparar as médias dessas amostras entre si. A fórmula do teste T de uma amostra é dada por (KIM, 2015):

$$T = \frac{(\bar{x} - \mu)}{\left(\frac{s}{\sqrt{n}}\right)} \quad (2.5)$$

Onde $\bar{x}$ é a média da amostra, μ é a média da população, s é o desvio padrão da amostra, e n é o tamanho da amostra. Já a fórmula do teste T de duas amostras é dada por (KIM, 2015):

$$T = \frac{(\frac{\bar{x}_1}{\bar{x}_2})}{\sqrt{((\frac{s_1^2}{n_1}) + (\frac{s_2^2}{n_2}))}} \quad (2.6)$$

Onde $\bar{x}_1$ e $\bar{x}_2$ são as médias das duas amostras, s_1 e s_2 são os desvios padrão das duas amostras, e n_1 e n_2 são os tamanhos das duas amostras. O valor de T é então comparado a uma tabela de valores críticos para verificar se é estatisticamente significativo. Se o valor de T for maior que o valor crítico, isso indica que a média da amostra é significativamente diferente da média da população ou que as médias das duas amostras são significativamente diferentes entre si.

2.2.1.4 Qui-quadrado

O teste do Qui-quadrado, ou *Chi-squared*, é uma ferramenta estatística amplamente utilizada para avaliar a independência entre duas variáveis categóricas em um conjunto de dados. Em outras palavras, ele ajuda a determinar se existe uma associação significativa entre as categorias dessas variáveis ou se elas são independentes uma da outra (VENKATESH; ANURADHA, 2019).

A fórmula do teste Qui-quadrado é essencial para calcular a estatística do teste. Ela é expressa como (VENKATESH; ANURADHA, 2019):

$$X^2 = \frac{\sum(O - E)^2}{E} \quad (2.7)$$

Onde, X^2 é a estatística do teste Qui-quadrado. O é a frequência real ou observada de eventos em cada categoria. E é a frequência esperada ou teórica de eventos em cada categoria, supondo que não há relação entre as variáveis. Esta é calculada com base nas proporções das margens totais das variáveis categóricas.

O numerador $(O - E)^2$ avalia a discrepância entre as observações reais e as esperadas em cada categoria, e o resultado é dividido pela frequência esperada E . Somando essas contribuições para todas as categorias, obtemos a estatística do teste X^2 . Calculado o valor X^2 da operação, é possível compará-lo com um valor crítico de Qui-quadrado para determinar se a associação entre as variáveis é estatisticamente significativa. Se o valor calculado for maior que o valor crítico, a hipótese nula de independência entre as variáveis categóricas é rejeitada.

2.2.1.5 Informação Mútua (MI)

A Informação Mútua (MI, do inglês *Mutual Information*) é uma técnica que mede a dependência entre duas variáveis (VENKATESH; ANURADHA, 2019). A fórmula da informação mútua é dada por (CAGNAZZO; ANTONINI; BARLAUD, 2010):

$$MI(X, Y) = \sum_{x,y} p(x, y) \log\left(\frac{p(x, y)}{p(x)p(y)}\right) \quad (2.8)$$

Onde X e Y são as duas variáveis sendo comparadas, $p(x)$ é a probabilidade de X ocorrer, $p(y)$ é a probabilidade de Y ocorrer, e $p(x, y)$ é a probabilidade conjunta de X e Y ocorrerem.

2.2.2 Métodos Embutidos

A seleção de características pelo método embutido é uma técnica de aprendizado de máquina que permite ao modelo escolher automaticamente as características mais relevantes para a tarefa. Em vez de selecionar as características manualmente ou por meio de um algoritmo externo, a seleção de características é realizada durante o próprio processo de treinamento. Isso permite que o modelo aprenda a importância relativa das características e se adapte a elas de forma eficiente (CHANDRASHEKAR; SAHIN, 2014).

2.2.2.1 Regularização Lasso

A regularização Lasso (*Least Absolute Shrinkage and Selection Operator*) funciona adicionando uma penalidade L1 ao erro do modelo, o que faz com que algumas das características sejam consideradas menos importantes e, assim, sejam reduzidas a zero na solução do modelo. Apenas as características com coeficientes não nulos são consideradas importantes para a solução do modelo, o que significa que a regularização Lasso efetivamente faz uma seleção de características durante o processo de treinamento (FONTI; BELITSER, 2017).

2.2.2.2 Árvores de decisão

A árvore de decisão funciona criando uma árvore com nós representando decisões e ramos representando possíveis resultados dessas decisões. O objetivo é encontrar a divisão ótima dos dados de treinamento em cada nó de modo a maximizar a separação entre as classes.

Na seleção de características, a árvore de decisão pode ser usada para identificar as características mais importantes para a separação dos dados. Isso é feito analisando a importância de cada característica nas divisões de nó realizadas na árvore. Características que são utilizadas com mais frequência para separar os dados são consideradas mais importantes (JAISWAL; SAMIKANNU, 2017).

2.2.2.3 Floresta aleatória

A floresta aleatória é um algoritmo de aprendizado de máquina baseado em várias árvores de decisão. Em vez de construir apenas uma árvore de decisão, a floresta aleatória

constrói várias árvores de decisão e usa a média ou voto para realizar a previsão final (JAISWAL; SAMIKANNU, 2017). Por ser um algoritmo que utiliza árvores de decisões, a seleção de característica também se assemelha ao algoritmo de árvores de decisões, citado na subseção anterior.

2.2.3 Métodos por Envoltórios

A seleção de características por envoltório é uma abordagem para seleção de características baseada no desempenho do modelo de classificação ou regressão. Visto que, objetivo é encontrar o subconjunto ótimo de características que maximiza o desempenho do modelo (VENKATESH; ANURADHA, 2019).

Um fator importante de ressaltar é que, os métodos de envoltório usam algoritmos externos para selecionar as características. Sendo que eles são aplicados antes do treinamento do modelo, e o modelo é treinado apenas nas características selecionadas.

A principal vantagem dessa categoria de seleção de características se dá pelo fato de que, os métodos de envoltório são úteis quando não há certeza sobre qual modelo usar ou quando há muitas características disponíveis (VENKATESH; ANURADHA, 2019). Nas subseções a seguir serão apresentadas algumas das técnicas de seleção de características por envoltórios mais comuns.

2.2.3.1 Busca exaustiva

Algoritmos de busca exaustiva são técnicas computacionais utilizadas para encontrar a solução ótima para um problema dado. Eles funcionam explorando completamente todas as possibilidades de uma solução até encontrar a melhor opção (LIU; MOTODA, 2012). Logo, vantagem deste tipo de algoritmo é a garantia de encontrar a solução ótima, uma vez que ele verifica todas as possibilidades.

No entanto, a desvantagem é o tempo de processamento, que pode ser muito longo em problemas complexos ou de grande escala. Para superar este problema, alguns algoritmos de busca exaustiva incluem heurísticas para descartar caminhos não promissores e reduzir o número de soluções avaliadas. Alguns dos principais algoritmos de busca exaustiva são:

- **Busca em profundidade (DFS):** O Algoritmo de Busca em Profundidade (DFS, sigla em inglês para *Depth-First Search*) é um método de busca que explora todas as possibilidades de uma solução de forma recursiva. Sendo que, o DFS começa por explorar uma possibilidade de solução e continua avaliando as opções consecutivas até chegar ao fim da busca ou encontrar a solução ótima.

Se uma solução viável não for encontrada, o algoritmo retorna e explora a próxima possibilidade. Este processo se repete até que a solução ótima seja encontrada ou

todas as opções tenham sido avaliadas (CORMEN et al., 2009).

- **Busca em largura (BFS):** O objetivo do Algoritmo de Busca em Largura (BFS, do inglês *Breadth-First Search*) é encontrar a solução ótima a um problema de busca explorando todos os nós adjacentes antes de seguir para nós mais distantes. Onde, utiliza-se uma fila para armazenar os nós (conjuntos de características) a serem visitados. E, a cada iteração, o primeiro nó na fila é removido e todos os seus nós adjacentes são adicionados na fila. O processo continua até que todos os nós tenham sido visitados ou até que a solução seja encontrada (CORMEN et al., 2009).
- **Algoritmo de força bruta:** A execução do Algoritmo de Força Bruta (do inglês *Brute Force*) envolve a geração de todas as combinações possíveis de soluções e a verificação da sua validade. O processo é repetido até que a solução correta seja encontrada ou até que todas as combinações possíveis tenham sido testadas (CORMEN et al., 2009).

2.2.3.2 Busca heurísticas

Algoritmos de busca heurística são técnicas que se baseiam em estimativas para encontrar soluções ótimas para problemas complexos. O objetivo destes algoritmos é encontrar uma solução aceitável em um tempo razoável, mesmo que ela não seja a melhor possível.

Os algoritmos de busca heurística funcionam por meio da avaliação de possíveis soluções baseadas em uma função heurística, que é uma estimativa da qualidade da solução. Esta função é projetada para levar em consideração as características do problema e pode ser personalizada de acordo com as necessidades do usuário. A partir desta avaliação, o algoritmo decide qual é a próxima solução a ser explorada, permitindo que ele evolua em direção à solução final (KOKASH, 2005).

A literatura é contemplada com diversos estudos e metodologias diferentes de busca heurísticas. Sendo que, os mais encontrados em estudos recentes são os algoritmos genéticos e os algoritmos de seleção sequenciais (VENKATESH; ANURADHA, 2019). Dado a importância desses algoritmos de seleção sequencial para esse trabalho, as 2 (duas) subseções a seguir serão destinadas a eles.

2.2.4 Algoritmos Genéricos

Os Algoritmos Genéticos (AG) representam uma abordagem de otimização inspirada nos processos de evolução biológica. Criados por John Holland na década de 1960, esses algoritmos buscam resolver problemas complexos de otimização e busca heurística, aplicando conceitos fundamentais de genética em soluções computacionais (LAMBORA; GUPTA; CHOPRA, 2019).

Em algoritmos genéticos, a menor variável capaz de guardar informações é chamada de gene. Um conjunto de genes forma um cromossomo, que por sua vez, funciona como estrutura de informação genética. Sendo que, a natureza dos cromossomos pode variar de acordo com o tipo de problema a ser solucionado, podendo ser binários (representando valores como 0 ou 1), inteiros ou reais.

A evolução, do algoritmo, ocorre por meio de operadores genéticos, sendo a recombinação (*crossover*) e a mutação as principais. O *crossover* simula a recombinação genética, onde pares de cromossomos trocam informações para criar descendentes que herdam características dos pais. Já a mutação introduz pequenas alterações aleatórias nos genes, garantindo diversidade genética na população (LAMBORA; GUPTA; CHOPRA, 2019).

A avaliação dos indivíduos que comporão a próxima geração é determinada pela função de aptidão (*fitness*). Sendo a função *fitness* responsável por guiar o processo evolutivo, privilegiando as soluções mais adaptadas. Depois de avaliados, os indivíduos da população passam por um processo de seleção, que leva em conta a aptidão do indivíduo, alguns processos de seleções comuns são os torneios e as roletas. Dito isso, a seguir serão apresentados os parâmetros do algoritmo genético usado nesse trabalho:

- **Tamanho da População:** Indica o número de indivíduos na população.
- **Taxa de recombinação (*Crossover*):** Representa a probabilidade de dois cromossomos trocarem informações genéticas.
- **Taxa de Mutação:** Determina a probabilidade de um gene ser alterado aleatoriamente.
- **Critério de Parada:** Define as condições para encerrar o algoritmo.
- **Função de Aptidão (*fitness*):** Avalia o desempenho de cada solução em relação ao problema, orientando a evolução da população.
- **Taxa de elitismo:** Defini quantos, dos melhores indivíduos irão passar para a próxima geração.

2.2.5 Algoritmos de seleção sequencial

Algoritmos de busca sequencial são técnicas usadas para procurar um elemento específico em uma coleção de dados. Eles são chamados de sequenciais porque examinam elementos em ordem, um a um, até encontrar o que está sendo procurado ou determinar que o elemento não existe na coleção (AHA; BANKERT, 1995). Existem dois tipos principais de algoritmos de busca sequencial: o *sequential forward search* e o *sequential backward search*.

2.2.5.1 Busca Sequencial para Frente

A busca sequencial para frente (*Sequential Forward Search* ou *Step Forward*), também conhecida como busca linear. Ela consiste em procurar o elemento procurado em cada elemento da coleção, começando pelo primeiro elemento e terminando no último. Se o elemento procurado é encontrado, a busca é interrompida e o índice do elemento é retornado. Este algoritmo é geralmente implementado como um *loop* que itera por cada elemento da coleção (AHA; BANKERT, 1995).

2.2.5.2 Busca Sequencial para Trás

A busca sequencial para trás (*Sequential Backward Search*) é similar à busca sequencial para frente, mas começa pelo último elemento da coleção e vai até o primeiro. Ela é útil em situações em que o elemento procurado é provável que seja encontrado no final da coleção. Assim como a busca sequencial para frente, a busca sequencial para trás é implementada como um *loop* que itera por cada elemento da coleção, mas começando do final (AHA; BANKERT, 1995).

2.3 Métricas de validação

As métricas de validação são medidas utilizadas para avaliar a precisão e eficiência de um modelo de aprendizado de máquina. Essas métricas permitem avaliar o desempenho de um modelo em comparação com o conjunto de dados de treinamento e o conjunto de dados de teste, fornecendo uma medida objetiva de sua capacidade de generalização (DALIANIS; DALIANIS, 2018). Alguns conceitos importantes para entender as fórmulas das principais métricas de validação são:

- **Verdadeiros positivos (TP):** são as previsões corretas do modelo na classe positiva. Por exemplo, em um problema de classificação de flores, um TP seria o caso em que o modelo previu corretamente a classe de um flor.
- **Falsos positivos (FP):** são as previsões erradas do modelo na classe positiva. Por exemplo, em um problema de classificação, um FP seria o caso em que o modelo previu incorretamente a classe de uma flor.
- **Verdadeiros negativos (TN):** são as previsões corretas do modelo na classe negativa. Por exemplo, em um problema de classificação de flores, um TN seria o caso em que o modelo previu corretamente que uma flor não pertencia a uma determinada classe.
- **Falsos negativos (FN):** são as previsões erradas do modelo na classe negativa. Por exemplo, em um problema de classificação de flores, um FN seria o caso em que o

modelo previu incorretamente que uma flor não pertencia a uma determinada classe, ou seja, a flor pertencia a classe em questão.

Nas subseções a seguir, serão apresentados algumas das principais métricas de validação. Sendo elas, acurácia, revocação, precisão, *F1-Score*.

2.3.1 Acurácia

A acurácia (ou *accuracy* em inglês) é a porcentagem de previsões corretas do modelo em relação ao total de previsões feitas (TEODORO; KAPPEL, 2020). A fórmula matemática da acurácia é dada por (SALIH; ABDULAZEEZ, 2021):

$$Acurácia = \frac{(TP + TN)}{(TP + TN + FP + FN)} \quad (2.9)$$

A acurácia é uma métrica útil para avaliar o desempenho do modelo quando as classes são balanceadas, ou seja, quando o número de exemplos em cada classe é aproximadamente igual. No entanto, a acurácia pode ser enganosa em casos de desequilíbrio de classes, pois o modelo pode ter uma alta acurácia simplesmente previsão a maioria das amostras como a classe majoritária, mesmo se o desempenho na classe minoritária for baixo.

2.3.2 Revocação

A revocação (em inglês, *recall*) mede a proporção de eventos positivos que são detectados corretamente pelo modelo em relação ao número total de eventos positivos na base de dados (TEODORO; KAPPEL, 2020). A fórmula matemática da revocação é dada por (SALIH; ABDULAZEEZ, 2021):

$$Revocação = \frac{TP}{(TP + FN)} \quad (2.10)$$

Nos casos em que os conjuntos de classes de treinamento, de um modelo de aprendizado de máquina, sejam desequilibradas, a revocação é útil para avaliar o desempenho do modelo na detecção de eventos positivos, pois ela mede a proporção de eventos positivos corretamente identificados pelo modelo.

2.3.3 Precisão

A precisão (*precision*) mede a proporção de previsões corretas em relação ao número total de previsões feitas pelo modelo (TEODORO; KAPPEL, 2020).

A métrica de precisão é útil em casos onde é necessário que o modelo seja capaz de fazer previsões corretas com mais frequência do que previsões incorretas. A fórmula matemática da precisão é dada por (SALIH; ABDULAZEEZ, 2021):

$$Precisão = \frac{TP}{(TP + FP)} \quad (2.11)$$

2.3.4 F1-Score

O F1-Score é uma métrica de validação que combina precisão e revocação em uma única medida de desempenho do modelo. É calculado como a média harmônica entre precisão e revocação, ou seja, a média que dá mais peso às medidas de menor valor (TEODORO; KAPPEL, 2020).

O F1-Score é útil quando ambos precisão e revocação são importantes para avaliar o desempenho do modelo. A fórmula matemática do F1-Score é dada por (SALIH; ABDULAZEEZ, 2021):

$$F1 - Score = 2 * \frac{(Precisão * Revocação)}{(Precisão + Revocação)} \quad (2.12)$$

2.4 Máquina de vetores de suporte (SVM)

As Máquinas de Vetor de Suporte (SVM, do inglês *Support Vector Machines*) foram desenvolvidas pela primeira vez na década de 1990 por Vladimir Vapnik e seus colegas. Inicialmente, elas foram criadas para resolver problemas de classificação binária, mas mais tarde foram ampliadas para incluir tarefas de regressão e classificação multiclasse (HEARST et al., 1998).

O SVM é baseado no teorema de separação de maximização da largura da margem, que afirma que é possível separar duas classes linearmente separáveis em um espaço de recursos de alta dimensão, encontrando o hiperplano de separação que maximiza a largura da margem entre as classes. Logo, objetivo do SVM é encontrar o hiperplano de separação que maximiza a margem entre as classes. Esse hiperplano é chamado de vetor de suporte, daí o nome "máquina de vetores de suporte". Os dados usados para treinar a máquina são chamados de vetores de suporte porque eles definem a posição e a direção do hiperplano (HEARST et al., 1998).

Os principais conceitos que caracterizam as máquinas de vetores de suporte são:

- **Hiperplano de separação:** Um hiperplano de separação é uma linha ou superfície que divide duas ou mais classes de dados em um espaço de características. Em SVMs,

o objetivo é encontrar o hiperplano que maximiza a margem, ou seja, a distância entre o hiperplano e os pontos mais próximos de cada classe de dados.


- **Margem:** A margem é a distância entre o hiperplano de separação e os pontos mais próximos de cada classe de dados em uma Máquina de Vetor de Suporte (SVM). Sendo que, quanto maior a margem, menor a probabilidade de erro do algoritmo.
- **Vetores de suporte:** Os vetores de suporte são pontos de dados mais próximos ao hiperplano de separação em uma Máquina de Vetor de Suporte (SVM). Eles são importantes porque determinam a forma e a posição do hiperplano de separação.

Logo, vale ressaltar que, os vetores de suporte são os pontos que, se removidos, mudariam a forma do hiperplano de separação. Eles são identificados durante o processo de treinamento do modelo SVM e são utilizados para definir o hiperplano de separação.

- **Função de canal:** A função *kernel* é uma transformação matemática que permite que os dados sejam transformados em um espaço de características de maior dimensão, onde eles possam ser separados por um hiperplano de separação. Em uma Máquina de Vetor de Suporte, a função *kernel* é usada para lidar com dados que não são linearmente separáveis na forma original. As três funções de canal que serão usadas nesse trabalho serão apresentadas na subseção 2.4.3.

A figura 1 ilustra o uso de um hiperplano para separar duas classes em um espaço bidimensional (BASTOS, 2007). Na imagem, Bastos (2007), apresenta dois exemplos de uso de hiperparâmetros para separação de classes, onde a figura à esquerda apresenta um exemplo linearmente separável, enquanto a figura à direita apresenta um exemplo de separação de classes não linearmente separável.

Figura 1 – Apresentação dos principais termos usados em máquinas de vetores de suportes.



Fonte: Bastos (2007).

2.4.1 SVM binário vs. SVM multiclasse

O SVM foi inicialmente desenvolvido para resolver problemas de classificação binária, ou seja, aqueles que envolvem a separação de duas classes distintas. Entretanto, ao

longo do tempo, os pesquisadores expandiram a aplicação do SVM para lidar com tarefas mais complexas, como regressão e classificação multiclasse.

Com relação ao SVM binário, o objetivo é encontrar um hiperplano de separação que maximize a margem entre duas classes distintas. Esse hiperplano é projetado para separar eficientemente as duas classes no espaço de características. Contudo, em problemas de classificação com mais de duas classes, existem duas abordagens principais para o utilizar com o SVM: a abordagem Um-contr-Um ("*One-vs-One*") e a abordagem Um-contr-Todos ("*One-vs-All*").

Ao usar o estratégia Um-contr-Um, um classificador binário é treinado para cada par único de classes. Se houver K classes, então serão necessários $(K * (K - 1))/2$ classificadores binários. Cada classificador é treinado para distinguir entre duas classes específicas. Durante a fase de teste, cada classificador vota na classe que ele prediz, e a classe que recebe mais votos é escolhida como a classe final. Vale destacar que esse é o algoritmo escolhido para esse trabalho.

Na abordagem Um-contr-Todos, um classificador é treinado para cada classe, considerando-a em relação a todas as outras classes. Se houver K classes, serão treinados K classificadores binários. Durante a fase de teste, cada classificador decide se a instância de entrada pertence à sua classe ou não. A classe predita é aquela associada ao classificador que tem a maior confiança em sua predição.

2.4.2 Hiperparâmetros do SVM estudados nesse Trabalho

- **C (Regularização):** O parâmetro de regularização C controla o equilíbrio entre a obtenção de uma margem mais ampla e a classificação correta dos pontos de treinamento. Um valor mais alto de C implica uma classificação mais precisa dos pontos de treinamento, mas pode resultar em uma margem mais estreita.
- **Kernel:** O *kernel* é uma função matemática que transforma os dados de entrada em um espaço de características de maior dimensão, facilitando a separação. Os *kernels* mais comuns incluem o linear, o *sigmoidal* e o de base radial (RBF).
- **Γ (γ):** O parâmetro γ controla a forma da função de base radial (RBF). Um valor mais alto de γ resulta em uma função RBF mais estreita, o que significa que os pontos de dados são considerados mais similares se estiverem próximos uns dos outros.
- **Tol (Tolerância):** O hiperparâmetro *tol* determina a tolerância para critérios de parada. Em termos simples, representa a precisão desejada para a solução do modelo SVM. Se a diferença entre as iterações sucessivas for menor que *tol*, o treinamento é

interrompido. Um valor adequado de *tol* pode ser importante para controlar o tempo de treinamento e evitar ajustes excessivos.

2.4.3 Funções de canais utilizadas no trabalho

- **Função Linear:** A função linear geralmente é usada, mas não se limitando, em problemas de classificação binária quando os dados são linearmente separáveis, ou seja, quando é possível separar as duas classes usando uma única linha reta. Ela consiste em calcular o produto escalar entre os vetores de entrada x e x' (PATLE; CHOUHAN, 2013). A forma geral da função linear é:

$$K(x, x') = x \cdot x' \quad (2.13)$$

Onde x e x' são pontos de dados e $\cdot$ é o produto escalar. A função linear é usada na SVM para calcular a similaridade entre cada par de pontos de dados, o que é usado para determinar se um ponto pertence a uma classe ou a outra.

- **Função Sigmoidal:** A função *sigmoidal* é chamada assim porque sua forma se parece com a forma de uma sigmoide. A função *sigmoidal* é usada na SVM para calcular a similaridade entre cada par de pontos de dados, o que é usado para determinar se um ponto pertence a uma classe ou a outra (HEARST et al., 1998). A forma geral da função *sigmoidal* é:

$$K(x, x') = \tanh(\alpha x \cdot x' + c) \quad (2.14)$$

Onde x e x' são pontos de dados, $\cdot$ é o produto escalar, α é um parâmetro de regularização que controla a inclinação da função *sigmoidal*, e c é um termo de deslocamento que controla a posição da função *sigmoidal*.

- **Função de base radial (RBF):** A função de base radial (*Radial basis function*) é chamada assim porque sua forma é baseada em uma função radial, ou seja, uma função que depende da distância radial entre um ponto e um centro. Ela para mapear os dados de entrada em um espaço de características mais elevado, onde eles podem ser separados linearmente (HEARST et al., 1998). A forma geral da função RBF é:


$$K(x, x') = \exp(-\gamma \|x - x'\|^2) \quad (2.15)$$

Onde x e x' são pontos de dados, $\|\cdot\|$ é a norma euclidiana e γ é um parâmetro de regularização que controla a largura da função RBF. Quanto maior o valor de γ , mais estreita será a função RBF, o que significa que os pontos de dados serão considerados mais similares se estiverem mais próximos um do outro.

3 Metodologia

Neste capítulo é apresentada a metodologia adotada no presente estudo. A primeira seção (Seção 3.1), discute quais dados serão usados e de onde serão obtidos. A Seção 3.2 apresenta informações sobre os rótulos gerados para treinamento do modelo usado para realizar a seleção de características. Por fim, na Seção 3.4 são apresentadas as técnicas adotadas nesse estudo.

Figura 2 – Overview da Metodologia deste Trabalho.



Fonte: Autoria própria.

A Figura 2 mostra uma visão geral de como o capítulo de metodologia está organizado. Ela separa cada seção por cores diferentes e apresenta o que será abordado na seção.

3.1 Dados

Os dados escolhidos para estudo foram os dados das ações listadas na bolsa de valores brasileira, (Brasil, Bolsa, Balcão - B3), apresentada no capítulo de introdução. E a forma de obter acesso aos dados das ações foi pelo banco de dados BovDB, apresentado na Seção 3.1.1.

3.1.1 BovDB

O banco de dados BovDB foi construído com o objetivo de disponibilizar um conjunto de dados, pré-processados, da bolsa de valores brasileira (B3), a fim de auxiliar pesquisas na área financeira (CARDOSO et al., 2022). Ele contém os dados das movimentações diárias de todas as ações listadas na B3 de 1995 a 2020.

A Tabela 2 apresenta algumas informações relevantes sobre o BovDB como os nomes das tabelas, a quantidade de ocorrências em cada tabela e qual a função de cada uma delas. E como o banco de dados foi produzido no idioma inglês os nomes das tabelas, consequentemente, estão em inglês. Logo, as informações contidas na Tabela 2 serão apresentadas em formato de lista, com os termos já traduzidos para o idioma principal utilizado nesse trabalho:

- **Evento (*events*):** Essa tabela armazena informações sobre eventos que ocorrem na B3, nela contém 12 ocorrências. Ou seja, entre outros dados encontrados na tabela são informados os tipos de eventos que podem acontecer na bolsa (CARDOSO et al., 2022).
- **Empresa (*company*):** A tabela, *company*, pode ser traduzida como "empresas", armazena informações sobre as empresas que participam ou já participaram da B3 entre os anos de 1995 a 2020. Logo, as 1728 ocorrências que aparecem na Tabela 2 representam 1728 registros de empresas que já passaram pela bolsa de valores brasileira.
- **Ação (*ticker*):** A tabela "ticker"(que pode ser traduzido como papel ou ação, em português) armazena as informações sobre as ações. O objetivo principal dessa tabela é relacionar os nomes das ações com um identificador próprio e com a empresa à qual ela pertence. Nela há registros de 2540 ações que já participaram da bolsa, dentro do período já especificado no primeiro parágrafo da subseção.
- **Evento-Preço (*eventprice*):** A tabela *eventprice* tem uma melhor tradução para o português como evento-preço, pois ela correlaciona os dias de pregões em que ocorreu algum evento em uma determinada ação. Além de informar qual o valor do *factor* (fator) de correção que deve ser aplicado na ação caso seja necessária uma análise temporal do comportamento da ação (informações sobre o *factor* na Seção 3.1.2).
- **Preço (*price*):** Esta tabela armazena informações sobre os pregões realizados na bolsa de valores, relacionando para cada ação em um determinado dia seus dados de negociações (ver Figura 3), sendo eles, os valores de *open* (abertura), *close* (fechamento), *high* (máxima), *low* (mínima), *average* (valor médio), *buy_offer* (melhor valor de venda), *sell_offer* (melhor valor de compra), *business* (número de

negociações), *amount_stock* (número de papéis negociados), *volume* (valor monetário total das ações negociadas) e *factor* (ver Seção 3.1.2).


Tabela 2 – Informações sobre as tabelas do banco de dados BovDB.

Tabelas	Números de ocorrências	Descrição
event	12	Tabela que informa os tipos de eventos que já foram registrados na bolsa.
company	1.728	Tabela que armazena informações sobre as empresas.
ticker	2.540	Tabela que armazena informações sobre as ações.
eventprice	26.967	Tabela que armazena informações sobre eventos, registrando quando uma ocorreu um evento em uma determinada ação e qual evento ocorreu.
price	1.843.399	Tabela que armazena informações sobre movimentos de ações, informando o que ocorreu em cada pregão.

Fonte: Adaptado de [Cardoso et al. \(2022\)](#).

A Figura 3 apresenta o esquema relacional do banco de dados BovDB. Nela é possível entender como as tabelas se relacionam, bem como, quais são as colunas de cada tabela. É possível entender mais sobre cada elemento da tabela no artigo de [Cardoso et al. \(2022\)](#).

Figura 3 – Modelo relacional do banco de dados BovDB.



Fonte: [Cardoso et al. \(2022\)](#).


3.1.2 Fator (*factor*)

Uma das características das bolsas de valores são as ocorrências de eventos corporativos (CARDOSO et al., 2022). Os eventos corporativos podem alterar as características das ações dado a necessidade de que a empresa detentora da ação julgar válida.

Um exemplo de evento é a bonificação, ela, geralmente, é aplicada quando a empresa julga que o valor de um papel está pouco acessível aos acionistas devido ao seu preço. Logo, a bonificação consiste em entregar mais papéis (ações) ao acionista de maneira proporcional ao número de ativos que esse acionista possui dividindo o papel dele em vários papéis de valor menor (CARDOSO et al., 2022).

A Figura 4 mostra o efeito do evento de bonificação no papel PETR4 da empresa Petróleo Brasil S.A.. Como é possível observar o valor da unidade da ação caiu de meados de R\$ 130,00 para, aproximadamente, R\$ 32,00. Entretanto, esse evento não afetou o valor da empresa, apenas distribuiu mais papéis no mercado de modo que o acionista que tinha 1 ação de, aproximadamente, R\$ 130,00 passou a ter 4 ações de, aproximadamente, R\$ 32,00.


Figura 4 – Exemplo do efeito do evento bonificação na ação PETR4, sem o *factor* aplicado.



Fonte: Adaptado de Cardoso et al. (2022).

Para que o efeito dos eventos corporativos não prejudiquem as análises de valorização e desvalorização dos papéis é necessário o uso do fator (*factor*) de correção. O que o *factor* faz é permitir a criação de um referencial temporal com o papel mais recente permitindo que valores do passado sejam comparáveis com toda a série temporal.

A Figura 5 mostra o mesmo intervalo de tempo para a ação PETR4, mostrado na Figura 4. Porém, com o uso do *factor* como fator de correção. Como é possível observar, pela Figura 5 não houve nenhuma mudança significativa no valor real da ação.

Figura 5 – Exemplo do efeito do evento bonificação na ação PETR4, com o *factor* aplicado.

Fonte: Adaptado de [Cardoso et al. \(2022\)](#).

3.2 Definindo rótulos de predição

A seleção de característica adotada nesse estudo é voltada para um problema de classificação. Logo, é necessário criar rótulos que serão usados para validar a técnica de seleção. Os rótulos adotados são:

- **Descida acentuada (DA):** refere-se a diferença do valor, em percentual, da movimentação da ação se comparada a um intervalo específicos de dias, de pregões, à frente. Onde o valor percentual é inferior ao valor apresentado na Tabela 3. Exemplo, se uma ação hipotética custa R\$ 20,00 no primeiro dia de negociação e no quinto dia ela esteja custando R\$ 18,00, seu valor caiu 10%, logo, ao usar a Tabela 3 como referência e analisar a janela histórica no valor de 5 dias, essa ação receberá um rótulo de descida acentuada para o intervalo de 5 dias de pregões.
- **Descida (D):** A lógica por trás da descida é quase a mesma lógica usada para explicar a descida acentuada. A diferença é que o valor que é considerado como descida é mais sutil que o valor da descida acentuada, sendo que, começa com um semifechado com o valor apresentado na coluna "Descida (D)" da Tabela 3 e o intervalo termina aberto com o valor apresentado na coluna "Descida acentuada (DA)".
- **Estabilidade (E):** o rótulo estabilidade representa as ações em que não tiveram uma variação significativa dentro do respectivo intervalo de tempo analisado. Seu intervalo de valores pode ser observado na Tabela 3, sendo que, é um intervalo aberto com valores começando pela coluna "Descida (D)" e terminando na coluna "Subida (S)".

- **Subida (S):** os rótulos de subida representam os pregões futuros, onde as ações tiveram uma subida sutil. Esse rótulo tem um intervalo semifechado começando com os valores "Subida (S)" e acabando aberto com os valores da coluna "Subida acentuada (SA)" apresentadas na Tabela 3.
- **Subida acentuada (SA):** A subida acentuada são os valores percentuais que tiveram um crescimento mais abrupto se comparado com os rótulos anteriores. Ele possui um intervalo semifechado que começa com os valores da coluna "Subida acentuada (SA)" da Tabela 3 e vai até o infinito positivo.

Tabela 3 – Relação dos rótulos com a janela histórica de predição.

Janela histórica (Pregões)	Descida acentuada (DA)	Descida (D)	Estabilidade (E)	Subida (S)	Subida acentuada (SA)
5	-4,00%	-1,00%		1,00%	4,00%
10	-5,50%	-1,50%		1,50%	5,50%
15	-6,75%	-1,75%		1,75%	6,75%
20	-8,25%	-2,00%		2,50%	8,75%
25	-9,00%	-2,50%		2,75%	9,25%
30	-10,00%	-2,75%		3,00%	10,25%
60	-13,50%	-3,75%		4,00%	15,00%
90	-18,50%	-4,75%		5,00%	18,50%

Fonte: Autoria própria.

Algumas informações importantes de serem comentadas sobre a criação dos rótulos é que os valores apresentados na Tabela 3 foram gerados comparando a variação percentual das principais ações da B3. Essa decisão foi tomada para reduzir a complexidade de comparar as variações de todas as ações listadas na bolsa e para equilibrar a quantidade de exemplo para cada classe nas 50 ações mais negociadas (IBrX-50), além de que, as principais ações são as que possuem mais peso e geram mais interesse entre as ações que estão na bolsa. Para definir quais as ações que seriam escolhidas, foram usadas as ações listadas no índice IBrX-50, cujo a tabela, com as ações listadas no índice, podem ser vistas na Tabela 15.

Outra informação importante é referente a distribuição de porcentagem entre os rótulos. A porcentagem entre os rótulos foi definida dividindo cada rótulo em quantidades amostrais parecidas, buscando, assim, manter o equilíbrio entre a quantidade de cada rótulo. Logo, pode ser observado que, em algumas janelas de predição a distribuição percentual entre descida acentuada e subida acentuada, bem como, entre descida e subida não se possui o mesmo valor modular.

Por fim, outras duas informações importantes para calcular o valor da variação percentual é que, para realizar o cálculo, é usado o valor de fechamento do dia como

referencial. E a última, refere-se à aplicação do *factor* em toda a série histórica para desconsiderar o efeito dos eventos no valor do papel.

3.3 Definindo indicadores de análise técnica

Como apresentado na Seção 1.1.1, o objetivo geral desse trabalho é realizar a seleção de possíveis conjuntos de indicadores técnicos que poderão ser usados como características na criação de algoritmos de predição das movimentações das ações no mercado financeiro. Sabendo disso, é necessário definir quais serão os indicadores de análise técnica que serão estudados.

Os indicadores serão gerados usando os dados obtidos pelo banco de dados BovDB, apresentado na Seção 3.1.1. Sendo importante ressaltar que, assim como na criação dos rótulos (Seção 3.2), é necessário a aplicação do *factor* em toda a série histórica para garantir a não interferência de eventos nos valores das ações.

Dito isso, a Tabela 4 apresenta as informações referente ao conjunto de indicadores técnicos que será usado na seleção de características. Ela é dividida em 5 (cinco) colunas, sendo elas:

- **Características:** nessa coluna são apresentados os tipos de indicadores de análise técnica usados no estudo. Sendo eles, média móvel, desvio padrão, MACD, RSI, VSDME, sinal e DF;
- **Intervalos e variações:** nessa coluna são mostrados os intervalos que cada indicador irá usar, sendo que um indicador poderá ter 1 (um) ou mais intervalos. Por exemplo, o indicador de índice de força relativa (RSI) irá calcular a força relativa nos intervalos de 7 (sete), 14 (quatorze) e 21 (vinte e um) pregões anteriores. Além de intervalos essa coluna também indica possíveis variações de um mesmo indicador técnico como é o caso do MACD.
- **Valores a ser calculados:** nessa coluna são apresentadas quais as variáveis que serão usadas no cálculo dos indicadores. Sendo que, cada indicador irá calcular para cada variável, dessa coluna, todos os intervalos apresentados na coluna "Intervalos e variações". Por exemplo, o indicador de média móvel possui 8 (oito) intervalos diferentes e 9 (nove) valores a serem calculados, dessa forma, haverá um total de 72 variações de médias móveis diferentes no conjunto total de características, visto que para cada um dos 8 intervalos terão 9 valores.
- **Nomenclatura:** nessa coluna é mostrada como será representada uma característica (indicador). A forma de representação do indicador é composta por uma abreviação do nome da técnica, do valor do intervalo ou variação (caso necessário) e do nome do

Tabela 4 – Indicadores técnicos que serão utilizado na seleção de características.

Características	Intervalos e variações [I]	Valores a serem calculados [V]	Nomenclatura	Quantidade de características
Média Móvel	5, 10, 15, 20, 25, 30, 60, 90	Abertura, fechamento, máximo, mínimo, médio, melhor valor de compra, melhor valor de venda, número de negociações, número de papeis negociados	mm_[I]_[V]	72
Desvio Padrão	5, 10, 15, 20, 25, 30, 60, 90	Abertura, fechamento, máximo, mínimo, médio, melhor valor de compra, melhor valor de venda, número de negociações, número de papeis negociados	sd_[I]_[V]	72
Convergência / Divergência de média móvel (MACD)	Histograma (hist), declive (slope), linha	Abertura, fechamento, máximo, mínimo, médio	macd[I]_[V]	15
Índice de força Relativa (RSI)	7, 14, 21	Abertura, fechamento, máximo, mínimo, médio	rsi_[I]_[V]	15
VSDME	12, 26	Abertura, fechamento, máximo, mínimo, médio	vsdme[I]_[V]	10
Sinal (<i>signal</i>)	9	Abertura, fechamento, máximo, mínimo, médio	signal_[V]	5
Diferença com relação ao preço anterior (DF)	1	Abertura, fechamento, máximo, mínimo, médio	df_[V]	5
Total				194

Fonte: Autoria própria.

valor a ser calculado. Por exemplo, ao gerar a nomenclatura de um índice de força relativa para um intervalo de 7 (sete) dias utilizando o valor de abertura de uma ação hipotética, o resultado da nomenclatura será "rsi_7_abertura".

- **Quantidade de características:** por fim, essa coluna apresenta a quantidade de

variações que cada indicador possui. Sendo que, o total de características estudadas nesse trabalho é de 194.

3.4 Abordagens adotadas

Esse estudo é voltado para seleção de características usando o método de envoltório (ver Seção 2.2.3). Sendo que, o algoritmo a ser avaliado pelos métodos que serão estudados é o algoritmo de máquina de vetores de suporte, apresentado na Seção 2.4.

O SVM, usado nesse estudo, é voltado para um problema de classificação multiclasse que utiliza o algoritmo de classificação Um-contra-Um (Seção 2.4.1). Como destacado nos objetivos específicos, serão testados diferentes valores de hiperparâmetros junto ao algoritmo SVM, sendo eles, os hiperparâmetros C , $kernel$, $gamma$ e tol , que podem ser visto na Seção 2.4.2.

Já com relação aos métodos de envoltórios, serão estudados o uso dos algoritmos de passo sequencial para frente (*Step Forward*) e algoritmos genéticos (GA), apresentados nas Seções 2.2.5.1 e 2.2.4, respectivamente. Sendo que, o algoritmo *Step Forward* será testado de duas formas diferentes, enquanto o algoritmo genético testado de uma única forma.

O primeiro método a ser avaliado, envolve o uso de *Step Forward* junto ao SVM, com diferentes tipos de *kernels*, porém, com os valores dos demais hiperparâmetros predefinidos. Dessa forma, além da seleção de características realizada, será avaliado qual *kernel* se mostrará mais adequado para dimensionar o problema de predição do mercado de ações utilizando indicadores técnicos. Bem como, será avaliada a capacidade de generalização dos rótulos, realizada pelo modelo, sem ajuste dos hiperparâmetros.

O segundo método utilizará algoritmo genético para realizar uma seleção conjunta de características e de hiperparâmetros do algoritmo SVM. Além da seleção de características, o algoritmo genético irá tentar ajustar os valores dos hiperparâmetros C , $gamma$ e tol , sendo que, ele irá usar valor de $kernel$ que apresentar o melhor resultado no primeiro método.

O terceiro método também estudará o algoritmo *Step Forward* junto ao SVM, porém utilizará os valores de hiperparâmetros ajustados pelo GA, no segundo método. Dessa forma, será avaliado como o *Step-Forward* se comporta utilizando esses hiperparâmetros, bem como, saber se é possível encontrar uma seleção de características mais eficaz que a encontrada pelo algoritmo genético, utilizando os mesmos hiperparâmetros.

Tanto o *Step Forward* quanto o algoritmo genético utilizam critérios de seleção em cada hipótese realizada. Sendo que, para o algoritmo genético o critério de seleção é realizado pela função *fitness*, enquanto cada hipótese recebe nome de indivíduo. Entretanto, por mais que o GA e o *Step Forward* possuam terminologias diferentes para definir os

critérios de seleções, ambos utilizarão os mesmos critérios.

Para definir quais grupos de características serão escolhidos em cada rodada (*Step Forward*), ou geração (algoritmo genético), serão usadas as métricas de avaliação de acurácia e *F1-Score* (ver Seção 2.3). Sendo que, enquanto a acurácia irá avaliar o desempenho geral do modelo, o *F1 Score* irá avaliar o desempenho geral, levando em consideração a performance de cada classe do modelo de classificação. Dito isso, para que o *F1-Score* consiga garantir a generalização dos rótulos nos modelos, seu cálculo será realizado da seguinte forma:

1. Calcular o *F1-Score* de cada classe.
2. Multiplicar todos os valores de *F1-Score* encontrados, formando um único valor proveniente dessa multiplicação.
3. Realizar uma radiciação, no valor encontrado no passo anterior, tendo como radical o número de classes que o problema possui.

Como essa forma de utilizar o *F1-Score* não foi encontrado em nenhuma literatura pesquisada, ela receberá o nome de *F1-Score* multiplicado e normalizado ou *F1-Score* normalizado, para melhor compreensão de que se trata, especificamente dessa fórmula, ao longo do estudo. A fórmula que descreve o *F1-Score* normalizado é dada por:

$$\sqrt[n]{\prod_{i=1}^n F1_Score(enésima_classe)} \quad (3.1)$$

Onde n é a quantidade de classes que o problema possui e $F1_Score(enésima_classe)$. O *F1-Score* será usado, dessa maneira, para garantir maior relevância aos modelos que possuírem os valores de *F1-Score* balanceados para cada classe, ao mesmo tempo que, atribui menor ou nenhuma relevância aos modelos de classificação com *F1-Score* próximos de zero ou desbalanceados.

Uma vez definido com quais métricas serão utilizadas para avaliar os algoritmos de seleções, serão definidos os passos usados como critério de avaliação. A avaliação de cada modelo será realizada da seguinte forma:

1. Será escolhido, pelo algoritmo de seleção, um subconjunto de características para ser avaliado.
2. Será gerado um modelo SVM utilizando os dados de treinamento, com subconjunto de dados escolhido.
3. Será usado o modelo gerado para prever os dados de validação.

4. Serão calculados os valores de acurácia, tanto para os dados de treino quanto para os dados de teste.
5. Será calculado o *F1-Score* normalizado dos dados de validação.
6. Será calculado o valor de *fitness* (GA), ou de critério de seleção (*Step-Forward*), utilizando a Fórmula 3.2, onde quanto maior é o valor de x mais eficiente é o subconjunto, logo mais chances de ser escolhido como melhor seleção de características.

$$x = 0,4*(acc_treino)+0,6*(acc_valid)+0,1*(F1_Score_normalizado_valid-1) \quad (3.2)$$

Sendo que, cada algoritmo define como escolherá o melhor subconjunto. No caso do *Step-Forward*, ao fim de cada rodada o subconjunto com o maior valor será o escolhido para a próxima rodada. Já no caso do algoritmo genético, a seleção ocorrerá de acordo com os valores dos cromossomos, população, elitismo, seleção de indivíduos e mutação (ver Seção 2.2.4).

4 Resultados

Nesse capítulo são apresentados os resultados e discussões do estudo realizado nesse trabalho, sendo dividido em 5 (cinco) seções. A primeira seção (Seção 4.1) apresenta como os dados foram tratados, processados e organizados.

A Seção 4.2 mostra os resultados alcançados, usando *Step-Forward*, sem a realização dos ajustes de hiperparâmetros do algoritmo SVM. Além disso, ela apresenta os valores padrões de hiperparâmetros do algoritmo de máquina de vetores de suporte.

A Seção 4.3 expõe os resultados da seleção de características, utilizando algoritmo genético. Ela apresenta os valores utilizados como parâmetros do algoritmo genético, bem como, apresenta os valores de hiperparâmetros, do algoritmo SVM, ajustados pelo algoritmo evolutivo.

A Seção 4.4 apresenta os resultados das seleções de características, usando o algoritmo *Step-Forward*, com os valores de hiperparâmetros que foram ajustados pelo algoritmo genético. Por fim, a Seção 4.5 apresenta comparações entre os conjuntos de indicadores técnicos escolhidos. Bem como, discussões sobre os resultados apresentados por cada método de seleção de características, estudado nesse trabalho.

4.1 Tratamento, processamento e organização dos dados

Utilizando os dados do banco de dados BovDB (ver Seção 3.1.1), foi gerado um banco de dados com os 194 indicadores, apresentados na Tabela 4, para cada ação contida no BovDB, com valores de indicadores entre 1995 à 2020. Depois de calculados os indicadores, foi realizada uma padronização dos dados para valores entre 0 e 1. Por fim, além de gerar o banco de dados de características, foi gerado um banco de dados para os rótulos, usando o método apresentado na Seção 3.2.

Além disso, para a realização do estudo foram escolhidas 3 (três) ações diferentes, bem como, 3 (três) intervalos de rótulos diferentes. As ações e rótulos escolhidos são apresentados na Tabela 5, que é organizada da seguinte forma:

- **Ações:** nessa coluna são exibidos os *tickers* das ações usadas;
- **Empresas:** nela são apresentadas as empresas ao qual pertence cada ação;
- **Rótulos:** já nessa coluna, são exibidos quais rótulos foram usados em cada papel.

As ações escolhidas para esse estudo leva em consideração o índice IBRx-50, apresentado na seção 3.2. Das quais, foram escolhidas 3 (três) ações entre as ações com maior

Tabela 5 – Ações e rótulos escolhidos para serem estudados.

Ações	Empresas	Rótulos
VALE3	Vale S.A.	5, 15, 30
PETR4	Petróleo Brasileiro S.A.	5, 15, 30
ITSA4	Itausa S.A.	5, 15, 30

Fonte: Autoria própria.

relevância na bolsa de valores brasileira. Já com relação aos rótulos, foi-se definido, empiricamente, escolher 3 (três) rótulos, visto que, um número maior de rótulos iria aumentar o número de testes para valores considerados altos para esse estudo.

Além disso, outra etapa aplicada aos dados foram o embaralhamento dos dados e a divisão entre treino, teste e validação. Sendo que, todos os dados das ações foram embaralhados seguindo o mesmo padrão de embaralhamento, para que os testes fossem realizados usando os mesmos conjuntos amostrais. Em seguida, os dados foram escolhidos, empiricamente, para serem separados entre treino, teste e validação na proporção de 50%, 25% e 25%, respectivamente, mantendo os rótulos distribuídos de maneira proporcional (entre DA, D, E, S, SA, apresentados na Seção 3.2), em cada conjunto de dados separados.

4.2 *Step Forward* sem ajuste de hiperparâmetros

O primeiro método apresentado, na Seção 3.4, a ser analisado foi o uso de máquinas de vetores de suporte (ver Seção 2.4) junto à técnica de seleção de características, por envoltório, de busca sequencial para frente, também chamado de *Step Forward* (ver seção 2.2.5.1). Nessa etapa do estudo, foram realizados testes utilizando a ação VALE3 da empresa Vale S.A. para o rótulo de predição de 5 dias.

Ao realizar o uso de algoritmos de aprendizado de máquina, como máquinas de vetores de suporte, é necessário definir os valores de hiperparâmetros que serão usados no ajuste da técnica. Dito isso, a Tabela 6 apresenta os valores dos hiperparâmetros do algoritmo SVM que foram usados nessa etapa. Como pode ser observado, ela possui 2 (duas) colunas, sendo elas:

- **Hiperparâmetros:** Nessa coluna são mostrados os nomes dos hiperparâmetros;
- **Valores:** Já a coluna de valores apresenta os valores que cada hiperparâmetros vão utilizar.

Os valores de hiperparâmetros, como apresentado na Tabela 6 foram fixos ao longo de todos os testes, com a exceção dos valores de *gamma* e *kernel*. Os valores de *gamma* foram variando a medida que as quantidades de características, do conjunto de treino,


Tabela 6 – Hiperparâmetros usados no algoritmo SVM para realização dos testes de seleção de características.

Hiperparâmetros	Valores
<i>Kernel</i>	Linear, sigmoid, RBF
<i>Gamma</i>	$\left(\frac{1}{\text{Número_de_características}}\right)$
<i>C</i>	1
<i>Tol</i>	0,0001

Fonte: Autoria própria.

aumentavam, com o calculo sendo definido como apresentado na tabela. Já com relação ao *kernel*, foram realizados os testes para 3 (três) tipos de *kernels* diferentes.


Como essa etapa do estudo foi realizada utilizando apenas 1 (uma) ação e 1 (um) rótulo de predição, contudo, 3 (três) valores de *kernels* diferentes, foram feitas 3 (três) análises de seleção de características. Sendo uma utilizando o *kernel* linear, outra o *kernel* sigmoide e a última análise utilizou o *kernel* RBF. Os resultados da multiplicação ajustada do *F1-Score* e da acurácia podem ser observados nos gráficos 6, 8 e 10 para os *kernels* linear, sigmoide e RBF, respectivamente.

Figura 6 – Gráficos mostrando os respectivos resultados do *F1-Score* normalizado e da acurácia, ao longo de cada rodada, para o canal Linear.

Fonte: Autoria própria.

Como pode ser observado na Figura 6, o valor de *F1-Score* ajustado, para o *kernel* linear, obteve um valor igual a 0 (zero) ao longo de todo o Step Forward, indicando que o *F1-Score* de pelo menos um rótulo se manteve zerado ao longo do teste de seleção de características. Esse fato pode ser observado na Figura 7, onde é apresentada a matriz de confusão gerada pelo modelo usando os dados de teste. Nela é possível observar que, ao utilizar o *kernel* linear sem ajustar os demais hiperparâmetros, o modelo tende a considerar todos os valores de saída como "Subida Acentuada".


Figura 7 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 5 (cinco) dias, para o *kernel* Linear.



Fonte: Autoria própria.

Já com relação a acurácia utilizando o kernel linear, os valores mantiveram estáveis ao longo dos testes de seleção de características. Sendo que, o melhor resultado, para a acurácia, ocorreu na rodada 193 (cento e noventa e três) com o valor de 24,08%.


Figura 8 – Gráficos mostrando os respectivos resultados do *F1-Score* normalizado e da acurácia, ao longo de cada rodada, para o canal sigmoide.



Fonte: Autoria própria.

Outro *kernel* usado para realização da seleção de características utilizando SVM foi o *sigmoidal*. O comportamento dessa seleção de características é observado na Figura

Figura 9 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 5 (cinco) dias, para o *kernel* Sigmoide.



Fonte: Autoria própria.

8. Nela é possível observar um valor de *F1-Score* ajustado relativamente melhor que o *F1-Score* ajustado do *kernel* linear apresentando uma diferença de até 15% em algumas rodadas.


Porém, mesmo que o valor tenha aumentado, com relação a análise anterior, os valores de comparativos entre a acurácia do modelo e o *F1-Score* possui uma grande diferença e esse fato pode ser comprovado ao analisar a Figura 9. Ela apresenta a matriz de confusão do modelo da melhor rodada de seleção de características e, assim como aconteceu com o SVM com o *kernel* linear, os resultados preditos tenderam a se concentrar em rótulos específicos.

Por fim, baseando-se no cálculo de critério de seleção apresentado na Seção 2.3, a rodada que obtiver o melhor conjunto de características utilizando o *kernel* sigmoide foi a 47 (quarenta e sete), possuindo 47 (quarenta e sete) características. A acurácia para esse conjunto foi de 23,68% e o *F1-Score* ajustado foi de 16,48%.

A última seleção de características apresentada nessa etapa do trabalho é a que utiliza o *kernel* RBF. O comportamento do resultado dos dados de teste preditos, ao longo das rodadas, podem ser conferidos na Figura 10. Além disso, a Figura 11 apresenta a matriz de confusão do melhor conjunto de características, utilizando o *kernel* em questão.


Como foi observado nos demais *kernels*, os valores do *F1-Score* ao longo das

Figura 10 – Gráficos mostrando os respectivos resultados do *F1-Score* normalizado e da acurácia, ao longo de cada rodada, para o canal RBF.



Fonte: Autoria própria.

Figura 11 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 5 (cinco) dias, para o *kernel* RBF.



Fonte: Autoria própria.

rodadas não foram próximos dos valores da acurácia. Sendo que, no melhor conjunto de características para o *kernel* RBF, que ocorreu na rodada 20 (vinte), a acurácia dos dados de teste foi de 27,34% e o do *F1-Score* foi de 9,42%. Além de que, ao analisar a matriz de confusão é possível observar a tendência do modelo em predizer os valores para o rótulo de "Subida".

4.3 Seleção de características e ajuste de hiperparâmetros utilizando Algoritmos Genéticos

O segundo método para seleção de características apresentado, na Seção 3.4, foi o uso de máquinas de vetores de suporte junto ao uso de algoritmos genéticos na seleção de características e de valores de hiperparâmetros do algoritmo SVM. Para essa etapa do estudo foram usadas as ações indicadas pela Tabela 5, bem como, os rótulos apresentados nela. Dessa forma, serão apresentadas um total de 9 (nove) seleções de características realizadas nessa etapa.

Com relação ao algoritmo genético, além da função *fitness*, que teve seu cálculo apresentado na Seção 3.4, foram definidos outros parâmetros, bem como, critérios de parada para a seleção de características. Dito isso, a Tabela 7 mostra os parâmetros usados no GA e seus respectivos valores. Ela possui 2 (duas) colunas, sendo elas:

- **Parâmetros:** essa coluna apresenta o nome do parâmetro ou critério de parada a ser avaliado;
- **Valores:** essa coluna indica os valores de cada parâmetro.

Tabela 7 – Valores dos parâmetros e critérios de paradas do Algoritmos Genético.

Parâmetros	Valores
Tipo	Binário
Cromossomo	245
População	10
Seleção	Torneio
Mutação	10%
Elitismo	1
Gerações sem mudança	5000
Geração máxima	12000

Fonte: Autoria própria.

Como destacado na Tabela 7, o algoritmo genético usado nesse estudo é do tipo binário, sendo que, cada indivíduo (ou cromossomo) possui 245 genes. Os indivíduos possuem uma subdivisões nos genes, onde, os primeiros 194 (cento e noventa e quatro) bits da esquerda para a direita representam as características, os próximos 16 (dezesesseis) bits armazenam os valores do hiperparâmetro C, os 15 (quinze) bits subsequentes guardam os valores de *gamma* e os últimos 10 bits armazenam os valores de *tol*.

Já com relação a população, cada geração possui 10 indivíduos, sendo que, sempre o melhor da geração anterior é renovado na geração seguinte. Os demais indivíduos são selecionados por torneios, para cruzamento, onde são sorteados 3 indivíduos, e posteriormente, escolhe-se o melhor entre eles.

E por fim, os últimos parâmetros, do algoritmo genético, à serem destacados são os critérios de paradas, que no caso desse algoritmo foram dois. O primeiro critério de parada acontece quando não ocorre mudança no valor da função *fitness* por 5000 (cinco mil) gerações. E o segundo critério acontece quando o treinamento atinge 12000 (doze mil) gerações.

Como destacado no primeiro parágrafo dessa seção, além da realização de seleção de características, houve, em conjunto, o ajuste dos valores de hiperparâmetros do algoritmo SVM. A Tabela 8 mostra os valores de hiperparâmetros escolhidos em cada seleção de características, sendo que, nessa seção foi definido o RBF, como *kernel* do SVM. É válido destacar que os valores apresentados, na tabela, referem-se ao conjunto final da seleção de características, ou seja, são os valores, de hiperparâmetros, que juntos ao conjunto de indicadores escolhidos conseguiram maximizar o valor da função *fitness*. Dito isso, a Tabela 8 é composta por 5 (cinco) colunas, sendo elas:

- **Ação:** Nessa coluna são apresentados os nomes das ações analisadas nessa etapa do estudo;
- **Rótulo:** A coluna rótulo apresenta os rótulos de predição que cada ação utilizou;
- **C:** Essa coluna contém os valores do hiperparâmetro C encontrado pelo algoritmo genético para cada ação em seu respectivo rótulo;
- **Gamma:** Nessa coluna são apresentados os valores de gamma para cada ação em seu respectivo rótulo, assim como acontece na coluna C;
- **Tol:** Essa coluna apresenta os valores de tol, utilizando a mesma lógica apresentada para a coluna C e gamma.


Tabela 8 – Relação entre ação, rótulos e hiperparâmetros escolhidos na seleção de características utilizando GA.

Ação	Rótulo	C	Gamma	Tol
VALE3	5	1241,79	142,36	1,34
VALE3	15	5172,12	141,36	1,75
VALE3	30	3850,36	5,49	1,34
PETR4	5	4739,06	46,54	0,12
PETR4	15	2881,55	64,39	0,78
PETR4	30	1431,77	15,71	0,8
ITSA4	5	8287,45	45,93	1,18
ITSA4	15	7181,76	6,1	0,51
ITSA4	30	9338,81	279,85	1,58

Fonte: Autoria própria.


Apresentado os valores dos hiperparâmetros encontrados no processo evolutivo, nos parágrafos a seguir serão apresentados dados relevantes com relação a cada seleção de características. Serão apresentados a quantidade de indicadores escolhidos em cada seleção, os valores de *fitness*, acurácia e *f1-Score* ajustado encontrados e quais foram os critérios de paradas usados.

Figura 12 – Gráfico com o comportamento da função *fitness* ao longo do treinamento com os dados da ação VALE3 para um período de 5 (cinco) dias de predição.



Fonte: Autoria própria.

Figura 13 – Gráficos de acurácia e *F1-Score* normalizado da empresa VALE3 para predição de 5 (cinco) dias.



Fonte: Autoria própria.

A primeira análise apresentada é para a ação VALE3 para o rótulo de 5 (cinco) dias, a Figura 12 apresenta o comportamento do valor de *fitness* ao longo das gerações, em


um gráfico de linhas. A Tabela 12 mostra o comportamento evolutivo do melhor indivíduo (em azul), do pior indivíduo (em laranja) e da média do fitness da população (em verde).

Sendo que, devido ao fato que a média dos valores *fitness*, muitas vezes, se aproximavam dos valores de *fitness* do melhor indivíduo a linha representativa dele não se destaca ao longo do gráfico. Outro ponto a ser destacado, referente ao comportamento do gráfico, é que ao longo das gerações os piores indivíduos obtiveram um comportamento oscilatório, variando entre um valor próximo do melhor indivíduo à valores próximos ou iguais a 0 (zero).

Dito isso, o melhor conjunto de características para a ação VALE3 com o rótulo de 5 (cinco) dias, obteve 98 (noventa e oito) indicadores técnicos, sendo encontrada na rotada 7430 (sete mil quatrocentas e trinta), com um valor de *fitness* de 49,65%. Tendo como critério de parada atingir 12000 (doze mil) gerações.

Já com relação a acurácia e *F1-Score* normalizado, seus valores e comportamentos ao longo das gerações podem ser acompanhados na Figura 13. Sendo que, assim como acontece no gráfico apresentado na Figura 12, tanto o gráfico de acurácia quanto o gráfico de *F1-Score* normalizado, apresentam os comportamentos evolutivos do melhor indivíduo (em azul), do pior indivíduo (em laranja) e da média do fitness da população (em verde). O valor de acurácia do indivíduo com melhor *fitness* é de 28,51%, já o de *F1-Score* normalizado é de 25,41%.


Figura 14 – Gráfico com o comportamento da função *fitness* ao longo do treinamento com os dados da ação VALE3 para um período de 15 (quinze) dias de predição.



Fonte: Autoria própria.

As Figuras 14 e 15 mostram, respectivamente, os comportamentos dos valores de

Figura 15 – Gráficos de acurácia e $F1$ -Score normalizado da empresa VALE3 para predição de 15 (quinze) dias.



Fonte: Autoria própria.

fitness, acurácia e $F1$ -Score ao longo das gerações para a ação VALE3 com o rótulo de predição de 15 (quinze) dias. É importante ressaltar que, a forma com que os gráficos estão configurados, segue o padrão dos gráficos apresentados para a empresa VALE3 com o rótulo de 5 (cinco) dias, e analogicamente, isso também ocorre para as demais seleções de características apresentadas nessa seção.


O processo de seleção de características, da ação VALE3 para o rótulo de 15 (quinze) dias, teve o máximo valor *fitness* atingido na geração 9043 (nove mil e quarenta e três), atingindo um valor de 51,96%, com a seleção de 103 (cento e três) indicadores técnicos. O critério de parada foi atingir 12000 (doze mil) gerações, como pode ser visto na Figura 14. Já com relação aos valores de acurácia e $F1$ -Score, acurácia do indivíduo com melhor *fitness* foi de 31,93% e o $F1$ -Score normalizado foi de 28,06%, sendo observado na Figura 15.

Com o rótulo de 30 (trinta) dias, a ação VALE3 obteve o melhor conjunto de características na geração 3375 (três mil trezentos e setenta e cinco) com um valor *fitness* de 56,41% e 102 (cento e dois) indicadores técnicos escolhidos. Seu critério de parada foi atingir 5000 (cinco mil) gerações sem melhora, parando na geração 8375 (oito mil trezentos e setenta e cinco), esses dados podem ser acompanhados por meio da análise da Figura 16.

A Figura 17 apresenta os gráficos de acurácia e $F1$ -Scores da ação VALE3 com o rótulo de 30 (trinta) dias, respectivamente. A acurácia do indivíduo com melhor *fitness* foi de 38,52%, já o $F1$ -Score normalizado foi de 37,27%.


A analisando a Figura 18, é possível verificar o comportamento da evolução dos valores da função *fitness* para a ação PETR4 com o rótulo de predição de 5 (cinco) dias. Essa seleção de característica obteve o valor máximo na geração 2033 (dois mil e trinta e três), atingindo o valor *fitness* de 50,45%, sendo escolhidos 98 (noventa e oito) indicadores técnicos. O critério de parada para esse caso foi 5000 rotadas sem evolução, tendo um

Figura 16 – Gráfico com o comportamento da função *fitness* ao longo do treinamento com os dados da ação VALE3 para um período de 30 (trinta) dias de predição.



Fonte: Autoria própria.

Figura 17 – Gráficos de acurácia e *F1-Score* normalizado da empresa VALE3 para predição de 30 (trinta) dias.




Fonte: Autoria própria.

total de 7033 (sete mil e trinta e três) rotadas.

Já observando a Figura 19, é possível observar o comportamento dos valores de acurácia e *F1-Score* do rótulo de 5 (cinco) dias da ação PETR4. A acurácia do indivíduo com melhor *fitness* foi de 29,47% e o *F1-Score* foi de 27,67%.


As Figuras 20 e 21 apresentam, respectivamente, os valores de *fitness*, acurácia e *F1-Score* da seleção de características usando a ação PETR4 com o rótulo de 15 (quinze) dias. O valor máximo de *fitness* atingido foi de 53,73%, na geração 11471 (onze mil quatrocentos e setenta e um), selecionando 105 (cento e cinco) indicadores técnicos. Bem

Figura 18 – Gráfico com o comportamento da função *fitness* ao longo do treinamento com os dados da ação PETR4 para um período de 5 (cinco) dias de predição.



Fonte: Autoria própria.

Figura 19 – Gráficos de acurácia e *F1-Score* normalizado da empresa PETR4 para predição de 5 (cinco) dias.




Fonte: Autoria própria.

como, alcançando uma acurácia de 34,58% e um *F1-Score* de 28,80%.

A Figura 22 apresenta a evolução dos valores de *fitness*, ao longo das gerações para a ação PETR4 com o rótulo de 30 (trinta) dias. Sendo que o indivíduo que obteve o maior valor *fitness* foi encontrado na geração 8992 (oito mil novecentos e noventa e dois), com um valor *fitness* de 50.70%, utilizando 91 (noventa e um) indicadores.


Já a Figura 23 apresenta os valores de acurácia e *F1-Score* da ação PETR4 para os rótulos de 30 (trinta) dias de predição. O valor de acurácia do indivíduo com melhor *fitness* foi de 29,70% e o valor do *F1-Score* normalizado é de 28,79%.

Figura 20 – Gráfico com o comportamento da função *fitness* ao longo do treinamento com os dados da ação PETR4 para um período de 15 (quinze) dias de predição.



Fonte: Autoria própria.

Figura 21 – Gráficos de acurácia e *F1-Score* normalizado da empresa PETR4 para predição de 15 (quinze) dias.




Fonte: Autoria própria.

As Figuras 24 e 25 mostram o comportamento dos valores de *fitness*, acurácia e *F1-Score* normalizado, respectivamente, para a ação ITSA4 com um rótulo de 5 (cinco) dias. A geração que obteve o melhor indivíduo foi a geração 11138 (onze mil cento e trinta e oito), com um valor *fitness* de 50,07%, com 95 (noventa e cinco) indicadores técnicos escolhidos. Os valores de acurácia e *F1-Score* foram respectivamente, de 28,79% e 28,03%.


A última ação, da lista de ações escolhidas para estudo, foi a ação ITSA4. A Figura 26 apresenta o rótulo de predição de 15 (quinze) dias dessa ação. Foi encontrado o melhor conjunto de características na geração 10130 (dez mil cento e trinta), com um valor *fitness*

Figura 22 – Gráfico com o comportamento da função *fitness* ao longo do treinamento com os dados da ação PETR4 para um período de 30 (trinta) dias de predição.



Fonte: Autoria própria.

Figura 23 – Gráficos de acurácia e *F1-Score* normalizado da empresa PETR4 para predição de 30 (trinta) dias.




Fonte: Autoria própria.

de 53,98%, com a seleção de 94 (noventa e quatro) indicadores de análise técnica.

A Figura 27 mostra os gráficos de acurácia e *F1-Score* normalizado utilizando o rótulo de predição de 15 (quinze) dias da ação ITSA4. A acurácia do melhor conjunto de características foi de 34,39% e o *F1-Score* normalizado foi de 33,48%.


As Figuras 28 e 29 apresentam os comportamentos das métricas de avaliação usados nessa seção para a ação ITSA4 com o rótulo de predição de 30 (trinta) dias. Sendo que, o indivíduo com o melhor valor de *fitness* foi de 53,62%, encontrado na geração 11202 (onze mil duzentos e dois), utilizando 98 (noventa e oito) indicadores na seleção de características.

Figura 24 – Gráfico com o comportamento da função *fitness* ao longo do treinamento com os dados da ação ITSA4 para um período de 5 (cinco) dias de predição.



Fonte: Autoria própria.

Figura 25 – Gráficos de acurácia e *F1-Score* normalizado da empresa ITSA4 para predição de 5 (cinco) dias.




Fonte: Autoria própria.

A acurácia desse indivíduo foi de 34,47% e o *F1-Score* normalizado foi de 29,90%.

4.4 *Step Forward* com os hiperparâmetros ajustados


O terceiro método para a seleção de características proposto, na Seção 3.4, foi o uso de *Step Forward* junto ao algoritmo SVM, com os hiperparâmetros ajustados pelo algoritmo genético, para a seleção de indicadores de análise técnica. Assim como no método anterior, para essa etapa do estudo foram usados as ações e os rótulos apresentados na

Figura 26 – Gráfico com o comportamento da função *fitness* ao longo do treinamento com os dados da ação ITSA4 para um período de 15 (quinze) dias de predição.



Fonte: Autoria própria.

Figura 27 – Gráficos de acurácia e *F1-Score* normalizado da empresa ITSA4 para predição de 15 (quinze) dias.




Fonte: Autoria própria.

Tabela 5. Dessa forma, serão apresentadas, nessa etapa, um total de 9 (nove) seleções de características.

Assim como no método da Seção 4.3, para essa etapa do estudo o *kernel* usado, no algoritmo de máquinas de vetores de suporte, foi o RBF. Os demais hiperparâmetros usados para cada seleção de características podem ser acompanhados pela Tabela 8.


A primeira ação a ser analisada é a ação VALE3 com um rótulo de predição de 5 (cinco) dias. A Figura 30 mostra o comportamento da acurácia e do *F1-Score* normalizado

Figura 28 – Gráfico com o comportamento da função *fitness* ao longo do treinamento com os dados da ação ITSA4 para um período de 30 (trinta) dias de predição.



Fonte: Autoria própria.

Figura 29 – Gráficos de acurácia e *F1-Score* normalizado da empresa ITSA4 para predição de 30 (trinta) dias.




Fonte: Autoria própria.

ao longo das rodadas. Como o estudo possui 194 (cento e noventa e quatro) indicadores, cada *Step Forward* contém 194 (cento e noventa e quatro) rodadas.

Dito isso, baseando-se no cálculo de critério de seleção mostrado da Seção 3.4, o melhor conjunto de características para a ação VALE3 com o rótulo de 5 (cinco) dias ocorreu na rodada 109 (cento e nove), sendo selecionados 109 (cento e nove) indicadores técnicos. A acurácia para esse estudo foi de 26,62% e o *F1-Score* foi 25,96%.


A Figura 31 mostra a matriz de confusão da ação VALE3 para o rótulo de 5 (cinco) dias. No quesito de análise comparativa, essa figura é a mais importante da seção, pois

Figura 30 – Gráficos mostrando os respectivos resultados do $F1-Score$ normalizado e da acurácia, ao longo de cada rodada, para o papel VALE3 para uma previsão de 5 dias.



Fonte: Autoria própria.

Figura 31 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 5 (cinco) dias com os hiperparametros ajustados pelo GA.




Fonte: Autoria própria.

nela é possível avaliar a mudança de comportamento dos resultados de predição quando comparada com a Figura 11, que utiliza a mesma ação, o mesmo rótulo e o mesmo *kernel*. Com os ajustes de hiperparâmetros realizados é possível avaliar uma maior generalização dos rótulos, o que também pode ser comprovado avaliando o valor do $F1-Score$ normalizado.


As Figuras 32 e 33 apresentam, respectivamente, o comportamento do $F1-Score$

Figura 32 – Gráficos mostrando os respectivos resultados do $F1-Score$ normalizado e da acurácia, ao longo de cada rodada, para o papel VALE3 para uma previsão de 15 dias.



Fonte: Autoria própria.

Figura 33 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 15 (quinze) dias com os hiperparâmetros ajustados pelo GA.




Fonte: Autoria própria.

normalizado e da acurácia, na ação VALE3 com o rótulo de 15 (quinze) dias, ao longo das rodadas, bem como, a matriz de confusão do conjunto de indicadores selecionado. O melhor conjunto de características foi encontrado na rodada 84 (oitenta e quatro), possuindo uma acurácia de 28,69% e um $F1-Score$ normalizado de 27,65%.


Para o rótulo de 30 (trinta) dias da ação VALE3, foram encontrados 88 (oitenta

Figura 34 – Gráficos mostrando os respectivos resultados do $F1-Score$ normalizado e da acurácia, ao longo de cada rodada, para o papel VALE3 para uma previsão de 30 dias.



Fonte: Autoria própria.


Figura 35 – Matriz de confusão, do conjunto de dados de testes, da ação VALE3 com predição de 30 (trinta) dias com os hiperparametros ajustados pelo GA.



Fonte: Autoria própria.


e oito) indicadores de análise técnica, na melhor rodada. O valor de acurácia desse conjunto foi de 36,54% e o de $F1-Score$ foi de 34,29%. Dito isso, a Figura 34 apresenta o comportamento do $F1-Score$ e da acurácia, ao longo das rodadas, utilizando a ação VALE3 com rótulo de 30 (trinta) dias. Já a Figura 35 mostra a matriz de confusão do melhor conjunto de características para essa ação.

Figura 36 – Gráficos mostrando os respectivos resultados do $F1-Score$ normalizado e da acurácia, ao longo de cada rodada, para o papel PETR4 para uma previsão de 5 dias.



Fonte: Autoria própria.

Figura 37 – Matriz de confusão, do conjunto de dados de testes, da ação PETR4 com predição de 5 (cinco) dias com os hiperparâmetros ajustados pelo GA.




Fonte: Autoria própria.

As Figuras 36 e 37 mostram os valores de $F1-Score$ normalizado e acurácia, ao longo das rodadas, para a ação PETR4 com um rótulo de predição de 5 (cinco) dias, além de apresentar a matriz de confusão do melhor conjunto de características encontrado. A rodada com o melhor valor, de critério de seleção, foi a rodada 165 (cento e sessenta e cinco), possuindo o mesmo número de indicadores selecionados. Bem como, possuindo um


valor de acurácia de 26,67% e um valor de $F1-Score$ normalizado de 26,19%.

Figura 38 – Gráficos mostrando os respectivos resultados do $F1-Score$ normalizado e da acurácia, ao longo de cada rodada, para o papel PETR4 para uma previsão de 15 dias.



Fonte: Autoria própria.

Figura 39 – Matriz de confusão, do conjunto de dados de testes, da ação PETR4 com predição de 15 (quinze) dias com os hiperparametros ajustados pelo GA.




Fonte: Autoria própria.

A Figura 38 contém os valores, ao longo de cada rodada, de acurácia e $F1-Score$ normalizado, para o rótulo de 15 (quinze) dias usando a ação PETR4. Bem como, a Figura 39 apresenta a matriz de confusão do conjunto de característica que obteve a melhor performance, baseado no critério de seleção (ver Seção 3.4).


A rodada que obteve o melhor conjunto de indicadores, para a ação PETR4 com o rótulo de 15 (quinze) dias, foi a 56 (cinquenta e seis). O valor de acurácia foi de 30,87% e de *F1-Score* normalizado foi de 28,33%.

Figura 40 – Gráficos mostrando os respectivos resultados do *F1-Score* normalizado e da acurácia, ao longo de cada rodada, para o papel PETR4 para uma previsão de 30 dias.



Fonte: Autoria própria.

Figura 41 – Matriz de confusão, do conjunto de dados de testes, da ação PETR4 com predição de 30 (trinta) dias com os hiperparametros ajustados pelo GA.




Fonte: Autoria própria.

A análise dos dados da seleção de características da ação PETR4, com o rótulo de 30 (trinta) dias, pode ser realizada observando as figuras 40 e 41. Nessa seleção de


características foram selecionados 153 (cento e cinquenta e três) indicadores. Além disso, a acurácia foi de 35,69% e o $F1-Score$ normalizado foi de 33,67%.

Figura 42 – Gráficos mostrando os respectivos resultados do $F1-Score$ normalizado e da acurácia, ao longo de cada rodada, para o papel ITSA4 para uma previsão de 5 (cinco) dias.



Fonte: Autoria própria.

Figura 43 – Matriz de confusão, do conjunto de dados de testes, da ação ITSA4 com predição de 5 (cinco) dias com os hiperparâmetros ajustados pelo GA.




Fonte: Autoria própria.

A primeira análise para a ação ITSA4, nessa seção, pode ser observada nas Figuras 42 e 43, onde é usado o rótulo de 5 (cinco) dias. O melhor conjunto de características,


para essa ação com esse rótulo, usou 183 (cento e oitenta e três) indicadores técnicos e obteve uma acurácia de 28,17%, com um $F1-Score$ normalizado de 27,74%.

Figura 44 – Gráficos mostrando os respectivos resultados do $F1-Score$ normalizado e da acurácia, ao longo de cada rodada, para o papel ITSA4 para uma previsão de 15 dias.



Fonte: Autoria própria.

Figura 45 – Matriz de confusão, do conjunto de dados de testes, da ação ITSA4 com previsão de 15 (quinze) dias com os hiperparametros ajustados pelo GA.




Fonte: Autoria própria.

Já os resultados para o rótulo de 15 (quinze) dias da ação ITSA4, podem ser vistos nas Figuras 44 e 45, onde foram selecionadas 185 (cento e noventa e cinco) características,


no melhor caso. O valor de acurácia, melhor caso, foi de 31,59% e o valor do *F1-Score* normalizado foi de 30,89%.

Figura 46 – Gráficos mostrando os respectivos resultados do *F1-Score* normalizado e da acurácia, ao longo de cada rodada, para o papel ITSA4 para uma previsão de 30 dias.



Fonte: Autoria própria.

Figura 47 – Matriz de confusão, do conjunto de dados de testes, da ação ITSA4 com predição de 30 (trinta) dias com os hiperparametros ajustados pelo GA.



Fonte: Autoria própria.

Por fim, as Figuras 46 e 47 apresentam os dados da ação ITSA4 para o rótulo de 30 (trinta) dias. A rodada que obteve o melhor conjunto de características, para essa análise,

foi a 144 (cento e quarenta e quatro). Sendo que, a acurácia foi de 31,05% e o *F1-Score* foi de 28,25%.

4.5 Análises comparativas e discussões

As tabelas completas com a relação entre quantidade de indicadores escolhidos e método de seleção de características usados podem ser acompanhados nos apêndices (A, B, C e D), desse trabalho. São apresentadas 4 (quatro) tabelas com os dados das seleções de características.

A primeira tabela é a Tabela 11, nela é possível observar a relação entre as escolhas de todos os indicadores técnicos gerados com todas as seleções de características, realizadas nesse trabalho. As demais tabelas são relacionadas, separadamente, para cada método estudado.

Sendo que, a Tabela 12 apresenta os resultados de seleção para o algoritmo genético. A Tabela 13 apresenta os resultados da seleção de características, usando o algoritmo *Step-Forward* com os valores de hiperparâmetros ajustados. E a Tabela 14 mostra os resultados de seleção referentes ao *Step-Forward* sem ajustes de hiperparâmetros.

Em todas as tabelas o valor total que um indicador é escolhido é ordenado de forma decrescente, dessa forma os indicadores que foram mais escolhidos, estão ocupando as primeiras posições das tabelas. Logo, os indicadores técnicos que os algoritmos consideraram menos relevantes, estão ocupando as últimas posições das tabelas. As Tabelas 9 e 10 apresentam respectivamente, os 20 (vinte) melhores indicadores escolhidos por cada método de seleção e os 20 (vinte) piores indicadores.

Já com relação aos algoritmos de seleção de características, o uso de algoritmos genéticos para selecionar tanto as características quanto os hiperparâmetros dos algoritmos de aprendizado de máquina, se mostrou superior aos outros métodos. Sendo possível destacar que, não só houve uma seleção de característica que se comportou de forma homogênea, selecionando um número aproximado de indicadores técnicos, com diferentes ações e diferentes rótulo, como também, foi o método onde os modelos criados alcançaram um maior valor de acurácia e *F1-Score* normalizado.

Porém, é válido ressaltar que esse resultado superior que o algoritmo genético alcançou, frente aos algoritmos *Step-Forward*, pode ter sido influenciado pela escolha do algoritmo de aprendizado de máquina escolhido para esse estudo, SVM, que é fortemente influenciado por seus hiperparâmetros. Entretanto, mesmo para algoritmos de aprendizado de máquinas que não dependem tanto de hiperparâmetros, o uso de algoritmo genético pode se mostrar adequado, visto que, ele obteve a seleção de características mais homogênea, em números totais de indicadores por seleção.

Tabela 9 – Os 20 melhores indicadores de análise técnica para cada método de seleção de características.

	Todos	GA	Step-Forward (com ajuste)	Step-Forward (sem ajuste)
1º	macdslope_fechamento	mm_90_fechamento	mm_30_abertura	mm_30_oferta_compra
2º	macdslope_minimo	ifr_21_medio	macdslope_fechamento	mm_15_oferta_venda
3º	df_minimo	mm_20_oferta_compra	macdslope_maximo	mm_90_minimo
4º	macd_minimo	macdslope_minimo	dp_15_fechamento	mm_25_maximo
5º	dp_25_qtd_negocios	dp_60_qtd_negocios	macdslope_minimo	mm_15_minimo
6º	mm_90_fechamento	df_minimo	vsdme12_minimo	vsdme26_maximo
7º	mm_90_volume	df_fechamento	dp_15_volume	vsdme26_minimo
8º	mm_25_abertura	macd_minimo	dp_5_volume	vsdme26_medio
9º	mm_20_maximo	dp_60_minimo	mm_25_abertura	mm_25_qtd_negocios
10º	mm_20_abertura	dp_60_fechamento	mm_30_maximo	mm_25_oferta_compra
11º	mm_20_medio	dp_60_oferta_venda	mm_30_volume	mm_25_volume
12º	ifr_21_abertura	mm_20_medio	vsdme26_fechamento	dp_30_qtd_negocios
13º	df_fechamento	dp_90_oferta_venda	mm_60_abertura	dp_10_qtd_negocios
14º	ifr_21_maximo	mm_25_abertura	mm_90_volume	macd_maximo
15º	mm_15_fechamento	dp_90_abertura	dp_5_oferta_venda	mm_25_minimo
16º	mm_25_minimo	dp_30_qtd_negocios	macdslope_medio	df_minimo
17º	vsdme26_minimo	mm_30_fechamento	dp_10_abertura	vsdme26_fechamento
18º	mm_20_oferta_compra	dp_30_fechamento	mm_20_abertura	mm_5_abertura
19º	mm_30_maximo	dp_25_qtd_negocios	dp_10_volume	macdslope_abertura
20º	dp_10_abertura	mm_60_qtd_negocios	macdslope_abertura	vsdme12_medio

Fonte: Autoria própria.

Tabela 10 – Os 20 piores indicadores de análise técnica para cada método de seleção de características.

	Todos	GA	Step-Forward (com ajuste)	Step-Forward (sem ajuste)
1º	dp_30_oferta_venda	macd_medio	dp_5_oferta_compra	dp_15_maximo
2º	mm_25_qtd_negocios	dp_20_oferta_venda	dp_5_qtd_negocios	dp_15_abertura
3º	dp_60_abertura	mm_15_oferta_venda	dp_10_oferta_compra	dp_5_abertura
4º	mm_60_maximo	ifr_21_fechamento	dp_10_oferta_venda	dp_5_maximo
5º	macd_maximo	mm_15_qtd_negocios	dp_15_oferta_venda	dp_5_minimo
6º	dp_20_qtd_negocios	sinal_maximo	mm_90_maximo	dp_5_medio
7º	ifr_21_fechamento	dp_30_oferta_venda	dp_15_qtd_negocios	dp_5_fechamento
8º	ifr_7_abertura	ifr_7_fechamento	dp_30_fechamento	dp_5_oferta_compra
9º	mm_90_oferta_venda	ifr_7_maximo	dp_30_qtd_negocios	dp_5_oferta_venda
10º	dp_60_medio	dp_10_oferta_venda	ifr_14_minimo	dp_5_volume
11º	dp_20_oferta_venda	dp_25_maximo	mm_60_qtd_negocios	dp_10_abertura
12º	mm_60_fechamento	mm_60_fechamento	ifr_14_abertura	dp_10_maximo
13º	mm_15_qtd_negocios	dp_5_oferta_compra	dp_20_qtd_negocios	dp_10_minimo
14º	ifr_7_medio	mm_5_volume	ifr_7_abertura	dp_10_medio
15º	dp_25_maximo	dp_90_minimo	mm_15_qtd_negocios	dp_10_fechamento
16º	mm_10_medio	mm_10_medio	mm_25_qtd_negocios	dp_10_oferta_compra
17º	dp_10_oferta_venda	macd_abertura	mm_90_qtd_negocios	dp_10_oferta_venda
18º	dp_5_oferta_compra	macdhist_abertura	ifr_21_medio	dp_10_volume
19º	dp_10_maximo	macd_maximo	dp_90_minimo	ifr_21_medio
20º	dp_90_minimo	dp_10_maximo	mm_5_qtd_negocios	ifr_7_medio

Fonte: Autoria própria.

5 Conclusão

A união entre aprendizado de máquina e indicadores de análise técnica é cada vez mais usada para prever movimentos das ações no mercado financeiro. Uma vez que, com o uso de indicadores como Médias Móveis, desvio padrão, MACD, IFR, entre outros, pode ser possível criar modelos inteligentes capazes de antecipar o comportamento das ações. Contudo, para ter modelos eficazes, é essencial escolher um conjunto de indicadores que forneça informações relevantes para os algoritmos de aprendizagem de máquina.

Diante disso, essa pesquisa teve como objetivo geral, estudar o uso de seleção de características, em indicadores técnicos que possam ser úteis na criação de modelos de inteligência artificial, capazes de prever as movimentações das ações. Logo, conclui-se que o propósito foi atingido, visto que, foi possível realizar seleções de características, com diferentes métodos, destacando os indicadores mais usados na criação de modelos preditivos, pelo algoritmo SVM. Assim sendo que, para alcançar esses resultados, foram definidos diferentes objetivos específicos.

O primeiro objetivo específico foi utilizar algoritmos genéticos e *Step-Forward* como técnicas de seleção de características, aplicando-os no algoritmo SVM, com diferentes valores de hiperparâmetros. Para realizar esse propósito foi feito, em primeiro lugar, o uso de *Step Forward* com valores de hiperparâmetros do SVM definidos manualmente. O segundo teste foi utilizar algoritmos genéticos para realizar tanto a seleção de características, quanto a seleção de hiperparâmetros. Por fim, utilizando os valores de hiperparâmetros definidos pelo algoritmo genético, foi realizado outro teste usando o algoritmo *Step Forward* para selecionar os possíveis indicadores.

Já o segundo era propor os métodos, caso fossem validados. E visto que, os mesmos foram eficazes nas escolhas dos indicadores, eles se mostraram ser um passo importante na criação de modelos preditivos que utilizam indicadores financeiros. Entretanto, para algoritmos de inteligência artificial que necessitam uma maior atenção aos valores de hiperparâmetros, como no caso do SVM, o uso de algoritmo genético se mostrou superior ao *Step Forward*. Sendo assim, como proposto no terceiro objetivo (ver Seção 1.1.2), o uso de algoritmo genético se mostrou ser a solução mais completa entre os métodos de seleção estudados.

No mais, conclui-se que todos os algoritmos de seleção de características usados nesse estudo foram eficazes na seleção de características. Sendo que, os gráficos que acompanharam o processo de seleção de características utilizando *Step-Forward*, como o gráfico apresentado na Figura 30, mostraram a capacidade do algoritmo de aumentar a performance no modelo preditivo até encontrar o melhor conjunto e depois começar a cair.

Enquanto, o algoritmo genético apresenta o comportamento ir evoluindo a performance até encontrar o conjunto que chega próximo do ótimo. Os melhores indicadores, de cada método, podem ser vistos na Tabela 9, onde é possível comparar as escolhas das características entre si.

Para trabalhos futuros, poderão ser realizados teste utilizando outros algoritmos de aprendizado de máquinas, ou de aprendizado de máquina futuros, utilizando os indicadores considerados mais relevantes pelas seleções de características realizadas nesse estudo. Ou, realizar seleções de características utilizando outros algoritmos de aprendizado de máquinas como árvores de decisão, KNN, entre outros.

Também é possível fazer uma comparação mais ampla de uso algoritmos de seleção de características, testando outros métodos como os de filtragem e os métodos embutidos. Garantindo assim, um maior embasamento de quais métodos são mais eficazes para escolher indicadores financeiros.

Por fim, um trabalho futuro promissor, é saber se as metodologias adotadas nesse trabalho se aplicam em outros ativos financeiros, como no mercado de câmbio, de índices e em commodities. Bem como, avaliar o comportamento de ações de outras bolsas de valores.

Referências

- AHA, D. W.; BANKERT, R. L. A comparative evaluation of sequential feature selection algorithms. In: PMLR. *Pre-proceedings of the Fifth International Workshop on Artificial Intelligence and Statistics*. [S.l.], 1995. p. 1–7. Citado 2 vezes nas páginas 36 e 37.
- B3. *IBrx-50*. 2022. Disponível em: <https://www.b3.com.br/pt_br/market-data-e-indices/indices/indices-amplos/indice-brasil-50-ibrx-50-composicao-da-carteira.htm>. Citado na página 120.
- BARROS, T. d. S. Análise técnica e fundamentalista: ensaios sobre os métodos de análise. 2015. Citado 2 vezes nas páginas 23 e 24.
- BASTOS, F. A. C. de. *Classificador de modulações baseado em máquinas de vetores de suporte*. Tese (Doutorado) — UNIVERSIDADE FEDERAL DO RIO DE JANEIRO, 2007. Citado na página 40.
- CAELLI, T.; REYE, D. On the classification of image regions by colour, texture and shape. *Pattern recognition*, Elsevier, v. 26, n. 4, p. 461–470, 1993. Citado na página 27.
- CAGNAZZO, M.; ANTONINI, M.; BARLAUD, M. Mutual information-based context quantization. *Signal Processing: Image Communication*, Elsevier, v. 25, n. 1, p. 64–74, 2010. Citado na página 32.
- CARDOSO, F. C. et al. Bovdb: a data set of stock prices of all companies in b3 from 1995 to 2020. *Journal of Information and Data Management*, v. 13, n. 1, 2022. Citado 5 vezes nas páginas 23, 44, 45, 46 e 47.
- CHANDRASHEKAR, G.; SAHIN, F. A survey on feature selection methods. *Computers & Electrical Engineering*, Elsevier, v. 40, n. 1, p. 16–28, 2014. Citado 4 vezes nas páginas 27, 28, 30 e 33.
- CORMEN, T. H. et al. Computational geometry. *Introduction to Algorithms, 3rd ed.; The MIT Press: Cambridge, MA, USA*, p. 1022–1027, 2009. Citado na página 35.
- DALIANIS, H.; DALIANIS, H. Evaluation metrics and evaluation. *Clinical text mining: secondary use of electronic patient records*, Springer, p. 45–53, 2018. Citado na página 37.
- FONTI, V.; BELITSER, E. Feature selection using lasso. *VU Amsterdam research paper in business analytics*, Business Analytics Master Amsterdam, The Netherlands, v. 30, p. 1–25, 2017. Citado na página 33.
- HEARST, M. A. et al. Support vector machines. *IEEE Intelligent Systems and their applications*, IEEE, v. 13, n. 4, p. 18–28, 1998. Citado 2 vezes nas páginas 39 e 42.
- JAISWAL, J. K.; SAMIKANNU, R. Application of random forest algorithm on feature subset selection and classification and regression. In: IEEE. *2017 world congress on computing and communication technologies (WCCCT)*. [S.l.], 2017. p. 65–68. Citado 2 vezes nas páginas 33 e 34.

JARROW, R. A.; PROTTER, P. An introduction to financial asset pricing. *Handbooks in Operations Research and Management Science*, Elsevier, v. 15, p. 13–69, 2007. Citado na página 23.

JR, G. W. B. Evolution of the dow theory. *Financial Analysts Journal*, Taylor & Francis, v. 17, n. 5, p. 23–26, 1961. Citado na página 24.

KIM, T. K. T test as a parametric statistic. *Korean journal of anesthesiology*, The Korean Society of Anesthesiologists, v. 68, n. 6, p. 540–546, 2015. Citado na página 31.

KOKASH, N. An introduction to heuristic algorithms. *Department of Informatics and Telecommunications*, Citeseer, p. 1–8, 2005. Citado na página 35.

LAMBORA, A.; GUPTA, K.; CHOPRA, K. Genetic algorithm-a literature review. In: IEEE. *2019 international conference on machine learning, big data, cloud and parallel computing (COMITCon)*. [S.l.], 2019. p. 380–384. Citado 2 vezes nas páginas 35 e 36.

LI, J. et al. Feature selection: A data perspective. *ACM computing surveys (CSUR)*, ACM New York, NY, USA, v. 50, n. 6, p. 1–45, 2017. Citado na página 28.

LIU, H.; MOTODA, H. *Feature selection for knowledge discovery and data mining*. [S.l.]: Springer Science & Business Media, 2012. v. 454. Citado na página 34.

MITCHELL, T. M.; MITCHELL, T. M. *Machine learning*. [S.l.]: McGraw-hill New York, 1997. v. 1. Citado 2 vezes nas páginas 24 e 27.

MOBILIÁRIOS, C. de V. *Análise de investimentos: histórico, principais ferramentas e mudanças conceituais para o futuro*. [S.l.]: Rio de Janeiro: CVM, 2017. Citado na página 23.

PATLE, A.; CHOUHAN, D. S. Svm kernel functions for classification. In: IEEE. *2013 International Conference on Advances in Technology and Engineering (ICATE)*. [S.l.], 2013. p. 1–9. Citado na página 42.

PETRAM, L. The world's first stock exchange. In: *The World's First Stock Exchange*. [S.l.]: Columbia University Press, 2014. Citado na página 23.

SALIH, A. A.; ABDULAZEEZ, A. M. Evaluation of classification algorithms for intrusion detection system: A review. *Journal of Soft Computing and Data Mining*, v. 2, n. 1, p. 31–40, 2021. Citado 2 vezes nas páginas 38 e 39.

ST, L.; WOLD, S. et al. Analysis of variance (anova). *Chemometrics and intelligent laboratory systems*, Elsevier, v. 6, n. 4, p. 259–272, 1989. Citado 2 vezes nas páginas 30 e 31.

TEODORO, L. de A.; KAPPEL, M. A. A. Aplicação de técnicas de aprendizado de máquina para predição de risco de evasão escolar em instituições públicas de ensino superior no brasil. *Revista Brasileira de Informática na Educação*, v. 28, p. 838–863, 2020. Citado 2 vezes nas páginas 38 e 39.

VENKATESH, B.; ANURADHA, J. A review of feature selection and its methods. *Cybernetics and information technologies*, v. 19, n. 1, p. 3–26, 2019. Citado 6 vezes nas páginas 28, 29, 30, 32, 34 e 35.

WANG, J. The analysis of the financial market in china. *Academic Journal of Business & Management*, Francis Academic Press, v. 3, n. 2, 2021. Citado na página [23](#).

ZOU, K. H.; TUNCALI, K.; SILVERMAN, S. G. Correlation and simple linear regression. *Radiology*, Radiological Society of North America, v. 227, n. 3, p. 617–628, 2003. Citado na página [30](#).

Apêndices

APÊNDICE A – Tabela completa

comparando todos os indicadores técnicos com todas as seleções de características realizadas

Tabela 11 – Relação completa, comparando todos os métodos estudados com os indicadores gerados para estudo, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Step Forward (Não ajustado)		Algoritmo Genético			Step Forward (ajustado)			
	VALE3	VALE3	ITSA4	PETR4	VALE3	ITSA4	PETR4	
Indicadores	*	**	**	**	**	**	**	Total
macdslope_fechamento	(1, 0, 1)	(1, 1, 1)	(0, 1, 0)	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	18
macdslope_minimo	(1, 0, 0)	(1, 1, 1)	(1, 1, 1)	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	18
df_minimo	(1, 0, 1)	(1, 1, 1)	(1, 1, 0)	(1, 1, 1)	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	18
macd_minimo	(1, 0, 0)	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	16
dp_25_qtd_negocios	(1, 0, 1)	(1, 1, 1)	(1, 1, 0)	(1, 1, 0)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	16
mm_90_fechamento	(1, 0, 0)	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	16
mm_90_volume	(1, 0, 0)	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	16
mm_25_abertura	(1, 0, 0)	(1, 1, 0)	(1, 1, 1)	(1, 1, 0)	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	16
mm_20_maximo	(1, 1, 0)	(1, 1, 1)	(0, 0, 1)	(1, 1, 0)	(1, 1, 1)	(1, 1, 0)	(1, 1, 1)	16
mm_20_abertura	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	(0, 1, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	16
mm_20_medio	(1, 1, 0)	(1, 1, 1)	(0, 1, 1)	(1, 0, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	16
ifr_21_abertura	(1, 0, 1)	(1, 1, 0)	(1, 1, 1)	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	(1, 1, 0)	16
df_fechamento	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	(1, 1, 1)	(1, 0, 1)	(1, 1, 0)	(1, 1, 1)	16
ifr_21_maximo	(1, 0, 1)	(0, 0, 1)	(1, 1, 1)	(1, 1, 0)	(1, 1, 1)	(0, 1, 1)	(1, 0, 1)	15
mm_15_fechamento	(1, 0, 0)	(0, 1, 1)	(0, 1, 1)	(0, 1, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	15
mm_25_minimo	(1, 1, 0)	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	15
vsdme26_minimo	(1, 1, 0)	(1, 1, 0)	(0, 1, 1)	(1, 1, 1)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	15
mm_20_oferta_compra	(1, 1, 0)	(1, 1, 1)	(0, 1, 1)	(1, 1, 1)	(1, 0, 0)	(0, 0, 1)	(1, 1, 1)	15
mm_30_maximo	(1, 0, 0)	(1, 0, 1)	(1, 0, 1)	(1, 1, 0)	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	15
dp_10_abertura	(1, 0, 0)	(1, 1, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	15
mm_15_volume	(1, 0, 0)	(1, 1, 0)	(1, 1, 1)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	15
mm_30_abertura	(1, 0, 0)	(0, 1, 1)	(0, 1, 1)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	15
mm_15_abertura	(1, 1, 0)	(0, 1, 1)	(0, 1, 0)	(1, 1, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	15
dp_60_qtd_negocios	(1, 0, 1)	(1, 1, 1)	(0, 1, 1)	(1, 1, 1)	(0, 0, 1)	(0, 1, 1)	(0, 1, 1)	15
mm_15_medio	(1, 0, 0)	(1, 1, 1)	(0, 1, 0)	(1, 0, 0)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	14
mm_15_oferta_compra	(1, 0, 1)	(1, 0, 1)	(1, 1, 1)	(0, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	14

Tabela 11 – Relação completa, comparando todos os métodos estudados com os indicadores gerados para estudo, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Indicadores	Step Forward (Não ajustado)	Algoritmo Genético			Step Forward (ajustado)			Total
	VALE3	VALE3	ITSA4	PETR4	VALE3	ITSA4	PETR4	
	*	**	**	**	**	**	**	
mm_25_volume	(1, 0, 1)	(0, 1, 1)	(1, 0, 0)	(1, 0, 1)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	14
macdslope_abertura	(1, 0, 1)	(0, 0, 1)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	14
mm_30_fechamento	(1, 0, 0)	(0, 1, 1)	(0, 1, 1)	(1, 1, 1)	(1, 0, 0)	(0, 1, 1)	(1, 1, 1)	14
dp_20_medio	(1, 0, 0)	(1, 1, 0)	(0, 1, 1)	(0, 1, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	14
dp_20_maximo	(1, 0, 0)	(1, 0, 1)	(1, 1, 0)	(0, 1, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	14
dp_10_volume	(1, 0, 0)	(0, 0, 1)	(1, 0, 1)	(1, 0, 1)	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	14
macd_fechamento	(1, 0, 0)	(1, 1, 0)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	14
senal_abertura	(1, 0, 1)	(1, 0, 1)	(1, 0, 0)	(1, 1, 1)	(1, 0, 1)	(1, 0, 0)	(1, 1, 1)	14
dp_60_fechamento	(1, 0, 0)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	(0, 0, 0)	(1, 1, 1)	(1, 1, 0)	14
mm_90_minimo	(1, 1, 1)	(1, 1, 0)	(0, 0, 1)	(1, 0, 0)	(1, 0, 1)	(1, 0, 1)	(1, 1, 1)	14
dp_5_volume	(1, 0, 0)	(0, 1, 0)	(0, 1, 0)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	14
dp_60_oferta_venda	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	(1, 0, 1)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	14
dp_90_medio	(1, 0, 0)	(0, 1, 0)	(1, 1, 0)	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	14
dp_60_minimo	(1, 0, 0)	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	(0, 0, 1)	(1, 0, 1)	(1, 1, 0)	14
mm_15_minimo	(1, 1, 1)	(1, 0, 1)	(0, 0, 0)	(0, 0, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	14
vsdme12_minimo	(1, 0, 0)	(1, 0, 1)	(0, 0, 1)	(0, 1, 0)	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	14
dp_60_volume	(1, 0, 0)	(1, 1, 1)	(0, 1, 1)	(0, 0, 1)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	14
mm_90_oferta_compra	(1, 0, 0)	(1, 1, 1)	(1, 0, 0)	(1, 1, 1)	(1, 0, 0)	(0, 0, 1)	(1, 1, 1)	13
dp_30_volume	(1, 0, 0)	(1, 0, 1)	(0, 0, 0)	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	13
dp_5_abertura	(1, 0, 0)	(1, 0, 0)	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	13
dp_25_minimo	(1, 0, 0)	(1, 1, 1)	(0, 1, 1)	(0, 0, 1)	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	13
dp_5_maximo	(1, 0, 0)	(1, 1, 0)	(0, 0, 1)	(1, 1, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	13
dp_15_qtd_negocios	(1, 0, 1)	(1, 1, 1)	(0, 0, 1)	(1, 1, 1)	(0, 0, 1)	(0, 0, 1)	(1, 1, 0)	13
dp_30_medio	(1, 0, 0)	(1, 1, 0)	(0, 0, 1)	(1, 0, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	13
dp_5_fechamento	(1, 0, 0)	(0, 1, 1)	(1, 1, 0)	(0, 0, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	13
dp_30_minimo	(1, 0, 0)	(1, 1, 0)	(0, 1, 0)	(1, 0, 0)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	13
dp_5_oferta_venda	(1, 0, 0)	(0, 1, 0)	(0, 0, 1)	(1, 1, 0)	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	13
dp_5_qtd_negocios	(1, 0, 1)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	(0, 0, 1)	(0, 0, 1)	(1, 1, 0)	13
dp_25_abertura	(1, 0, 0)	(1, 1, 0)	(0, 1, 1)	(1, 0, 1)	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	13
dp_15_maximo	(1, 0, 0)	(1, 0, 1)	(1, 0, 1)	(0, 0, 1)	(0, 1, 0)	(1, 1, 1)	(1, 1, 1)	13
dp_25_volume	(1, 0, 0)	(1, 1, 1)	(1, 0, 0)	(0, 1, 0)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	13
dp_10_fechamento	(1, 0, 0)	(0, 1, 0)	(0, 1, 1)	(1, 1, 1)	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	13
dp_25_oferta_compra	(1, 0, 0)	(0, 0, 0)	(1, 1, 1)	(1, 1, 1)	(1, 0, 1)	(1, 0, 1)	(1, 0, 1)	13
dp_10_qtd_negocios	(1, 0, 1)	(1, 1, 1)	(1, 1, 0)	(0, 1, 0)	(0, 0, 1)	(0, 1, 1)	(1, 1, 0)	13
dp_15_fechamento	(1, 0, 0)	(0, 0, 0)	(0, 0, 1)	(0, 1, 1)	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	13

Tabela 11 – Relação completa, comparando todos os métodos estudados com os indicadores gerados para estudo, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Indicadores	Step Forward (Não ajustado)	Algoritmo Genético			Step Forward (ajustado)			Total
	VALE3	VALE3	ITSA4	PETR4	VALE3	ITSA4	PETR4	
	*	**	**	**	**	**	**	
dp_20_abertura	(1, 0, 0)	(1, 1, 0)	(0, 1, 1)	(0, 0, 1)	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	13
mm_60_volume	(1, 0, 0)	(0, 1, 0)	(0, 1, 0)	(1, 1, 1)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	13
macdslope_maximo	(1, 0, 0)	(0, 1, 0)	(0, 0, 1)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	13
mm_5_fechamento	(1, 0, 0)	(0, 0, 1)	(0, 0, 1)	(1, 1, 0)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	13
ifr_7_minimo	(1, 0, 1)	(1, 0, 0)	(0, 0, 1)	(1, 1, 0)	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	13
vsdme26_maximo	(1, 1, 0)	(1, 1, 0)	(0, 1, 0)	(0, 0, 1)	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	13
mm_10_oferta_compra	(1, 1, 0)	(0, 1, 1)	(0, 1, 1)	(1, 1, 0)	(1, 0, 0)	(1, 0, 1)	(1, 1, 0)	13
vsdme26_fechamento	(1, 1, 0)	(0, 1, 0)	(1, 0, 0)	(0, 1, 0)	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	13
mm_10_volume	(1, 0, 0)	(0, 1, 0)	(1, 1, 0)	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	13
mm_15_maximo	(1, 1, 0)	(1, 0, 1)	(1, 0, 0)	(0, 0, 1)	(0, 1, 0)	(1, 1, 1)	(1, 1, 1)	13
mm_20_fechamento	(1, 1, 0)	(1, 0, 1)	(1, 1, 0)	(0, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	13
mm_20_oferta_venda	(1, 0, 0)	(1, 1, 0)	(1, 0, 1)	(0, 1, 1)	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	13
macdslope_medio	(1, 0, 0)	(0, 1, 1)	(0, 1, 0)	(0, 0, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	13
mm_25_maximo	(1, 1, 1)	(1, 0, 1)	(1, 0, 0)	(0, 1, 0)	(1, 1, 1)	(1, 0, 0)	(1, 0, 1)	13
vsdme12_abertura	(1, 0, 0)	(0, 0, 0)	(1, 1, 1)	(0, 1, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 0)	13
mm_60_abertura	(1, 0, 0)	(1, 0, 0)	(1, 0, 1)	(1, 0, 0)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	13
dp_90_abertura	(1, 0, 0)	(0, 1, 1)	(1, 1, 1)	(1, 0, 1)	(0, 0, 1)	(0, 0, 1)	(1, 1, 1)	13
dp_90_qtd_negocios	(1, 0, 1)	(1, 1, 1)	(0, 1, 0)	(0, 1, 1)	(0, 0, 1)	(0, 0, 1)	(1, 1, 1)	13
mm_60_medio	(1, 0, 0)	(0, 1, 1)	(1, 1, 1)	(0, 1, 0)	(0, 0, 0)	(1, 1, 1)	(1, 1, 1)	13
dp_90_volume	(1, 0, 0)	(1, 1, 0)	(1, 0, 0)	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	13
macdhist_medio	(1, 0, 0)	(1, 0, 1)	(0, 1, 1)	(0, 0, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 0)	13
vsdme26_medio	(1, 1, 0)	(0, 1, 0)	(1, 1, 1)	(1, 0, 0)	(0, 1, 0)	(1, 0, 1)	(1, 1, 0)	12
dp_20_minimo	(1, 0, 0)	(0, 0, 1)	(0, 0, 1)	(0, 0, 1)	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	12
ifr_14_medio	(1, 0, 1)	(1, 1, 0)	(1, 1, 0)	(1, 0, 0)	(0, 0, 1)	(1, 1, 0)	(1, 0, 1)	12
dp_20_fechamento	(1, 0, 0)	(0, 1, 0)	(1, 1, 1)	(0, 0, 1)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	12
ifr_14_fechamento	(1, 0, 0)	(1, 1, 0)	(1, 1, 1)	(1, 1, 0)	(1, 0, 1)	(0, 0, 1)	(1, 0, 0)	12
dp_20_volume	(1, 0, 0)	(0, 0, 1)	(1, 0, 0)	(0, 1, 1)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	12
df_medio	(1, 0, 0)	(1, 0, 1)	(0, 0, 0)	(1, 0, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	12
dp_30_fechamento	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	(1, 0, 1)	(0, 0, 0)	(1, 0, 0)	(1, 1, 1)	12
dp_90_oferta_venda	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	(1, 0, 1)	(0, 0, 1)	(1, 0, 0)	(1, 1, 0)	12
dp_25_fechamento	(1, 0, 0)	(0, 0, 1)	(0, 1, 0)	(0, 1, 1)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	12
dp_30_qtd_negocios	(1, 0, 1)	(0, 1, 1)	(1, 1, 1)	(0, 1, 1)	(0, 0, 0)	(0, 0, 1)	(1, 1, 0)	12
vsdme12_medio	(1, 0, 1)	(1, 0, 1)	(0, 1, 0)	(0, 1, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 0)	12
dp_30_abertura	(1, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 0, 0)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	12
dp_60_oferta_compra	(1, 0, 0)	(1, 1, 0)	(1, 0, 1)	(0, 1, 1)	(0, 0, 1)	(1, 0, 1)	(1, 1, 0)	12

Tabela 11 – Relação completa, comparando todos os métodos estudados com os indicadores gerados para estudo, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Indicadores	Step Forward (Não ajustado)	Algoritmo Genético			Step Forward (ajustado)			Total
	VALE3	VALE3	ITSA4	PETR4	VALE3	ITSA4	PETR4	
	*	**	**	**	**	**	**	
sinal_minimo	(1, 0, 1)	(1, 0, 0)	(1, 1, 0)	(1, 0, 0)	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	12
macdhist_fechamento	(1, 0, 1)	(0, 0, 0)	(0, 1, 1)	(1, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	12
macdhist_maximo	(1, 0, 0)	(0, 1, 0)	(1, 0, 0)	(1, 1, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	12
mm_5_abertura	(1, 0, 1)	(0, 0, 1)	(0, 1, 1)	(0, 1, 1)	(0, 0, 0)	(1, 1, 0)	(1, 1, 1)	12
dp_15_volume	(1, 0, 0)	(0, 0, 1)	(0, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	12
mm_30_oferta_compra	(1, 1, 1)	(0, 0, 1)	(0, 0, 0)	(0, 1, 1)	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	12
dp_10_minimo	(1, 0, 0)	(0, 1, 1)	(1, 1, 0)	(0, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	12
mm_10_abertura	(1, 0, 1)	(0, 1, 1)	(0, 1, 1)	(0, 0, 1)	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	12
mm_10_maximo	(1, 1, 0)	(1, 1, 1)	(0, 0, 0)	(0, 1, 0)	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	12
mm_10_minimo	(1, 1, 0)	(1, 1, 0)	(0, 0, 1)	(0, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	12
mm_10_fechamento	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	(0, 0, 0)	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	12
mm_20_minimo	(1, 0, 0)	(1, 0, 0)	(1, 1, 1)	(0, 1, 0)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	12
mm_20_volume	(1, 0, 0)	(1, 0, 1)	(0, 1, 0)	(0, 0, 1)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	12
mm_25_medio	(1, 0, 0)	(0, 1, 1)	(1, 1, 0)	(0, 1, 1)	(1, 0, 0)	(1, 0, 0)	(1, 1, 1)	12
mm_25_oferta_compra	(1, 1, 0)	(1, 0, 0)	(0, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 0, 1)	(1, 1, 1)	12
mm_30_minimo	(1, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 0, 0)	(1, 0, 0)	(1, 1, 0)	(1, 1, 1)	12
mm_30_volume	(1, 0, 0)	(0, 1, 0)	(0, 1, 1)	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	12
mm_60_minimo	(1, 0, 0)	(0, 1, 0)	(0, 0, 1)	(1, 0, 1)	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	12
mm_60_qtd_negocios	(1, 0, 1)	(1, 1, 1)	(0, 1, 1)	(0, 1, 1)	(0, 0, 1)	(0, 0, 1)	(0, 1, 0)	12
mm_90_medio	(1, 0, 0)	(0, 1, 1)	(1, 0, 0)	(0, 0, 1)	(1, 0, 0)	(1, 1, 1)	(1, 1, 1)	12
ifr_21_medio	(1, 0, 0)	(1, 1, 1)	(1, 1, 1)	(0, 1, 1)	(0, 0, 0)	(0, 0, 1)	(1, 1, 0)	12
dp_15_abertura	(1, 0, 0)	(1, 1, 0)	(1, 1, 0)	(1, 0, 0)	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	12
mm_30_qtd_negocios	(1, 0, 1)	(1, 0, 0)	(0, 1, 0)	(1, 0, 1)	(0, 0, 1)	(1, 0, 1)	(0, 1, 1)	11
dp_25_medio	(1, 0, 0)	(0, 0, 0)	(1, 0, 1)	(1, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	11
macdhist_minimo	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	(0, 0, 0)	(1, 0, 0)	(1, 0, 0)	(1, 1, 1)	11
dp_30_maximo	(1, 0, 0)	(0, 1, 1)	(0, 1, 0)	(0, 0, 1)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	11
mm_25_fechamento	(1, 0, 0)	(1, 0, 1)	(0, 0, 0)	(1, 1, 0)	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	11
mm_20_qtd_negocios	(1, 0, 1)	(0, 0, 1)	(1, 0, 0)	(0, 1, 1)	(0, 0, 1)	(1, 0, 1)	(1, 1, 0)	11
dp_15_minimo	(1, 0, 0)	(0, 0, 0)	(1, 1, 0)	(1, 1, 0)	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	11
sinal_fechamento	(1, 0, 1)	(1, 0, 1)	(0, 1, 0)	(0, 1, 0)	(1, 1, 0)	(1, 0, 0)	(1, 1, 0)	11
sinal_maximo	(1, 0, 1)	(0, 1, 0)	(0, 1, 0)	(0, 0, 0)	(1, 1, 1)	(1, 0, 1)	(1, 1, 0)	11
sinal_medio	(1, 0, 0)	(0, 1, 0)	(1, 0, 0)	(1, 1, 0)	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	11
vsdme12_maximo	(1, 0, 0)	(0, 0, 1)	(1, 0, 0)	(0, 1, 1)	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	11
mm_15_oferta_venda	(1, 1, 1)	(0, 0, 0)	(1, 0, 0)	(1, 0, 0)	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	11
vsdme26_abertura	(1, 0, 0)	(1, 0, 1)	(1, 0, 1)	(0, 1, 0)	(0, 0, 0)	(1, 1, 0)	(1, 1, 1)	11

Tabela 11 – Relação completa, comparando todos os métodos estudados com os indicadores gerados para estudo, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Indicadores	Step Forward (Não ajustado)	Algoritmo Genético			Step Forward (ajustado)			Total
	VALE3	VALE3	ITSA4	PETR4	VALE3	ITSA4	PETR4	
	*	**	**	**	**	**	**	
mm_10_oferta_venda	(1, 0, 0)	(0, 0, 0)	(0, 1, 1)	(1, 1, 1)	(0, 0, 1)	(1, 0, 0)	(1, 1, 1)	11
dp_15_medio	(1, 0, 0)	(1, 0, 1)	(0, 0, 0)	(0, 1, 1)	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	11
dp_15_oferta_compra	(1, 0, 0)	(0, 0, 1)	(0, 1, 0)	(1, 1, 1)	(0, 1, 0)	(1, 0, 1)	(1, 1, 0)	11
mm_5_oferta_compra	(1, 0, 1)	(1, 1, 0)	(0, 1, 0)	(0, 1, 0)	(0, 0, 1)	(0, 0, 1)	(1, 1, 1)	11
mm_5_medio	(1, 0, 0)	(0, 1, 0)	(1, 0, 0)	(0, 1, 1)	(0, 1, 1)	(1, 0, 0)	(1, 1, 1)	11
mm_5_minimo	(1, 0, 0)	(0, 1, 1)	(0, 0, 1)	(1, 1, 0)	(0, 1, 0)	(1, 0, 0)	(1, 1, 1)	11
ifr_21_minimo	(1, 0, 0)	(0, 0, 1)	(1, 1, 0)	(1, 1, 0)	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	11
mm_30_medio	(1, 0, 0)	(1, 1, 1)	(0, 1, 1)	(0, 0, 0)	(1, 0, 0)	(1, 0, 0)	(1, 1, 1)	11
mm_5_maximo	(1, 0, 0)	(0, 0, 1)	(1, 1, 1)	(0, 1, 1)	(0, 0, 0)	(1, 0, 0)	(1, 1, 1)	11
dp_60_maximo	(1, 0, 0)	(0, 0, 1)	(1, 0, 0)	(0, 0, 1)	(1, 0, 0)	(1, 1, 1)	(1, 1, 1)	11
dp_90_fechamento	(1, 0, 0)	(0, 1, 1)	(0, 1, 1)	(1, 0, 0)	(1, 0, 0)	(1, 0, 1)	(1, 1, 0)	11
dp_5_medio	(1, 0, 0)	(0, 0, 0)	(1, 1, 1)	(1, 0, 0)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	11
dp_5_minimo	(1, 0, 0)	(0, 0, 0)	(0, 1, 1)	(1, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	11
mm_60_oferta_venda	(1, 0, 0)	(1, 0, 0)	(1, 1, 0)	(0, 0, 1)	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	11
mm_60_oferta_compra	(1, 0, 0)	(0, 0, 0)	(1, 1, 1)	(1, 0, 0)	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	11
dp_10_medio	(1, 0, 0)	(1, 1, 0)	(1, 1, 0)	(0, 0, 1)	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	11
df_abertura	(1, 0, 0)	(0, 0, 0)	(0, 0, 1)	(1, 1, 1)	(1, 0, 0)	(1, 0, 1)	(1, 1, 0)	10
vsdme12_fechamento	(1, 0, 1)	(0, 0, 0)	(0, 1, 1)	(1, 0, 0)	(1, 0, 0)	(1, 1, 0)	(1, 1, 0)	10
mm_10_qtd_negocios	(1, 0, 1)	(1, 1, 1)	(0, 0, 0)	(0, 0, 1)	(0, 0, 1)	(0, 0, 1)	(1, 1, 0)	10
mm_90_qtd_negocios	(1, 0, 1)	(1, 1, 1)	(0, 0, 0)	(1, 1, 0)	(0, 0, 1)	(0, 0, 1)	(0, 1, 0)	10
df_maximo	(1, 0, 0)	(1, 0, 1)	(0, 0, 0)	(0, 1, 0)	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	10
dp_20_oferta_compra	(1, 0, 0)	(0, 0, 1)	(0, 1, 0)	(0, 1, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 0)	10
mm_90_abertura	(1, 0, 0)	(0, 1, 0)	(1, 0, 0)	(0, 0, 0)	(1, 1, 0)	(1, 1, 0)	(1, 1, 1)	10
mm_5_volume	(1, 0, 1)	(0, 0, 1)	(0, 0, 0)	(0, 0, 0)	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	10
mm_5_oferta_venda	(1, 0, 1)	(1, 0, 1)	(0, 1, 0)	(0, 0, 0)	(0, 0, 1)	(1, 0, 0)	(1, 1, 1)	10
ifr_14_maximo	(1, 0, 0)	(0, 1, 0)	(1, 1, 0)	(1, 1, 0)	(1, 0, 0)	(1, 0, 0)	(1, 1, 0)	10
ifr_14_minimo	(1, 0, 0)	(1, 1, 0)	(1, 0, 1)	(1, 1, 0)	(0, 1, 1)	(0, 0, 1)	(0, 0, 0)	10
dp_30_oferta_compra	(1, 0, 0)	(1, 0, 1)	(1, 0, 0)	(0, 0, 1)	(0, 1, 0)	(1, 0, 1)	(1, 1, 0)	10
mm_90_maximo	(1, 0, 0)	(1, 0, 0)	(1, 1, 0)	(1, 0, 1)	(0, 0, 0)	(0, 0, 1)	(1, 1, 1)	10
dp_90_oferta_compra	(1, 0, 0)	(1, 1, 0)	(0, 1, 0)	(1, 1, 0)	(0, 1, 0)	(1, 0, 0)	(1, 1, 0)	10
dp_90_maximo	(1, 0, 0)	(0, 1, 0)	(1, 1, 1)	(0, 0, 0)	(1, 0, 0)	(1, 0, 1)	(1, 1, 0)	10
mm_25_oferta_venda	(1, 0, 0)	(0, 1, 1)	(1, 0, 0)	(0, 0, 0)	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	10
dp_25_oferta_venda	(1, 0, 0)	(0, 1, 1)	(1, 0, 0)	(1, 0, 0)	(0, 0, 0)	(1, 0, 1)	(1, 1, 0)	9
macd_abertura	(1, 0, 0)	(0, 0, 0)	(0, 0, 0)	(1, 0, 0)	(1, 0, 1)	(1, 0, 1)	(1, 1, 1)	9
mm_30_oferta_venda	(1, 0, 0)	(1, 0, 0)	(0, 0, 1)	(0, 0, 1)	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	9

Tabela 11 – Relação completa, comparando todos os métodos estudados com os indicadores gerados para estudo, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Indicadores	Step Forward (Não ajustado)	Algoritmo Genético			Step Forward (ajustado)			Total
	VALE3	VALE3	ITSA4	PETR4	VALE3	ITSA4	PETR4	
	*	**	**	**	**	**	**	
dp_15_oferta_venda	(1, 0, 0)	(0, 0, 1)	(1, 0, 0)	(1, 1, 0)	(0, 0, 0)	(1, 0, 1)	(1, 1, 0)	9
macd_medio	(1, 0, 0)	(0, 0, 0)	(1, 1, 0)	(0, 0, 0)	(0, 0, 0)	(1, 1, 1)	(1, 1, 1)	9
ifr_14_abertura	(1, 0, 1)	(1, 1, 1)	(0, 0, 0)	(1, 0, 0)	(0, 1, 0)	(0, 0, 1)	(0, 1, 0)	9
macdhist_abertura	(1, 0, 1)	(0, 0, 0)	(0, 0, 0)	(0, 0, 0)	(1, 1, 1)	(1, 0, 1)	(1, 1, 0)	9
ifr_7_maximo	(1, 0, 0)	(0, 1, 0)	(0, 1, 0)	(0, 0, 0)	(1, 0, 1)	(1, 1, 0)	(0, 1, 1)	9
ifr_7_fechamento	(1, 0, 1)	(0, 0, 0)	(1, 0, 0)	(0, 0, 1)	(1, 1, 1)	(0, 0, 1)	(1, 0, 0)	9
mm_5_qtd_negocios	(1, 0, 1)	(1, 0, 0)	(1, 1, 1)	(1, 0, 1)	(0, 0, 0)	(0, 0, 0)	(0, 1, 0)	9
dp_10_oferta_compra	(1, 0, 0)	(0, 0, 0)	(1, 1, 0)	(0, 1, 1)	(0, 0, 0)	(1, 0, 0)	(1, 1, 1)	9
dp_30_oferta_venda	(1, 0, 0)	(1, 0, 0)	(0, 0, 1)	(0, 0, 0)	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	9
mm_25_qtd_negocios	(1, 0, 1)	(1, 0, 0)	(1, 0, 0)	(1, 1, 0)	(0, 0, 1)	(0, 0, 1)	(0, 1, 0)	9
dp_60_abertura	(1, 0, 0)	(0, 1, 0)	(0, 0, 1)	(0, 0, 1)	(0, 0, 0)	(1, 1, 1)	(1, 1, 0)	9
mm_60_maximo	(1, 0, 0)	(0, 1, 0)	(0, 1, 1)	(0, 0, 0)	(0, 0, 0)	(0, 0, 1)	(1, 1, 1)	8
macd_maximo	(1, 0, 1)	(0, 0, 0)	(0, 0, 0)	(0, 0, 0)	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	8
dp_20_qtd_negocios	(1, 0, 1)	(0, 0, 0)	(1, 0, 0)	(1, 1, 0)	(0, 0, 0)	(0, 0, 0)	(1, 1, 1)	8
ifr_21_fechamento	(1, 0, 0)	(0, 0, 1)	(0, 1, 0)	(0, 0, 0)	(0, 1, 1)	(0, 0, 1)	(1, 1, 0)	8
ifr_7_abertura	(1, 0, 1)	(0, 0, 0)	(0, 1, 1)	(0, 0, 1)	(0, 0, 1)	(0, 1, 0)	(0, 1, 0)	8
mm_90_oferta_venda	(1, 0, 0)	(0, 1, 0)	(1, 0, 0)	(1, 0, 0)	(1, 0, 0)	(0, 0, 0)	(1, 1, 1)	8
dp_60_medio	(1, 0, 0)	(0, 0, 1)	(0, 0, 0)	(1, 0, 1)	(0, 0, 0)	(1, 0, 1)	(1, 1, 0)	8
dp_20_oferta_venda	(1, 0, 0)	(0, 0, 1)	(0, 0, 0)	(1, 0, 0)	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	8
mm_60_fechamento	(1, 0, 0)	(0, 0, 1)	(0, 0, 0)	(0, 0, 0)	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	8
mm_15_qtd_negocios	(1, 0, 1)	(0, 0, 1)	(0, 0, 1)	(0, 0, 0)	(0, 0, 1)	(0, 1, 1)	(0, 0, 0)	7
ifr_7_medio	(0, 0, 0)	(1, 0, 0)	(0, 0, 1)	(0, 0, 1)	(0, 0, 1)	(1, 0, 0)	(1, 1, 0)	7
dp_25_maximo	(1, 0, 0)	(0, 0, 0)	(1, 0, 0)	(0, 0, 0)	(0, 1, 0)	(1, 0, 0)	(1, 1, 1)	7
mm_10_medio	(1, 0, 0)	(0, 0, 0)	(0, 1, 0)	(0, 0, 0)	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	7
dp_10_oferta_venda	(1, 0, 0)	(0, 1, 0)	(0, 0, 1)	(0, 0, 0)	(0, 0, 0)	(1, 0, 0)	(1, 1, 1)	7
dp_5_oferta_compra	(1, 0, 0)	(0, 0, 1)	(0, 0, 0)	(0, 0, 0)	(1, 0, 0)	(1, 0, 0)	(1, 1, 0)	6
dp_10_maximo	(1, 0, 0)	(0, 0, 0)	(0, 0, 0)	(0, 0, 0)	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	6
dp_90_minimo	(1, 0, 0)	(1, 0, 0)	(0, 0, 0)	(0, 0, 0)	(0, 0, 0)	(1, 0, 0)	(1, 0, 0)	4

(Concluído)

* (Linear, Sigmoid, RBF)

** (5, 15, 30)

Fonte: Autoria própria.

APÊNDICE B – Tabela completa de indicadores técnicos selecionados, usando Algoritmo Genético como seletor de características

Tabela 12 – Relação completa entre a seleção de características, usando algoritmo genético, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
mm_90_fechamento	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	9
ifr_21_medio	(1, 1, 1)	(1, 1, 1)	(0, 1, 1)	8
mm_20_oferta_compra	(1, 1, 1)	(0, 1, 1)	(1, 1, 1)	8
macdslope_minimo	(1, 1, 1)	(1, 1, 1)	(1, 1, 0)	8
dp_60_qtd_negocios	(1, 1, 1)	(0, 1, 1)	(1, 1, 1)	8
df_minimo	(1, 1, 1)	(1, 1, 0)	(1, 1, 1)	8
df_fechamento	(1, 1, 1)	(1, 1, 0)	(1, 1, 1)	8
macd_minimo	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	8
dp_60_minimo	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	8
dp_60_fechamento	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
dp_60_oferta_venda	(1, 1, 1)	(1, 1, 0)	(1, 0, 1)	7
mm_20_medio	(1, 1, 1)	(0, 1, 1)	(1, 0, 1)	7
dp_90_oferta_venda	(1, 0, 1)	(1, 1, 1)	(1, 0, 1)	7
mm_25_abertura	(1, 1, 0)	(1, 1, 1)	(1, 1, 0)	7
dp_90_abertura	(0, 1, 1)	(1, 1, 1)	(1, 0, 1)	7
dp_30_qtd_negocios	(0, 1, 1)	(1, 1, 1)	(0, 1, 1)	7
mm_30_fechamento	(0, 1, 1)	(0, 1, 1)	(1, 1, 1)	7
dp_30_fechamento	(1, 1, 1)	(1, 1, 0)	(1, 0, 1)	7
dp_25_qtd_negocios	(1, 1, 1)	(1, 1, 0)	(1, 1, 0)	7
mm_60_qtd_negocios	(1, 1, 1)	(0, 1, 1)	(0, 1, 1)	7
dp_15_qtd_negocios	(1, 1, 1)	(0, 0, 1)	(1, 1, 1)	7
mm_90_oferta_compra	(1, 1, 1)	(1, 0, 0)	(1, 1, 1)	7
mm_90_volume	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	7
mm_20_abertura	(1, 1, 1)	(1, 1, 0)	(0, 1, 1)	7

Tabela 12 – Relação completa entre a seleção de características, usando algoritmo genético, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
dp_5_qtd_negocios	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	7
vsdme26_minimo	(1, 1, 0)	(0, 1, 1)	(1, 1, 1)	7
ifr_14_fechamento	(1, 1, 0)	(1, 1, 1)	(1, 1, 0)	7
ifr_21_abertura	(1, 1, 0)	(1, 1, 1)	(0, 1, 1)	7
macdslope_fechamento	(1, 1, 1)	(0, 1, 0)	(1, 1, 1)	7
mm_15_volume	(1, 1, 0)	(1, 1, 1)	(1, 0, 0)	6
dp_20_medio	(1, 1, 0)	(0, 1, 1)	(0, 1, 1)	6
mm_5_qtd_negocios	(1, 0, 0)	(1, 1, 1)	(1, 0, 1)	6
dp_25_oferta_compra	(0, 0, 0)	(1, 1, 1)	(1, 1, 1)	6
dp_25_minimo	(1, 1, 1)	(0, 1, 1)	(0, 0, 1)	6
mm_60_medio	(0, 1, 1)	(1, 1, 1)	(0, 1, 0)	6
dp_25_abertura	(1, 1, 0)	(0, 1, 1)	(1, 0, 1)	6
dp_20_maximo	(1, 0, 1)	(1, 1, 0)	(0, 1, 1)	6
mm_10_oferta_compra	(0, 1, 1)	(0, 1, 1)	(1, 1, 0)	6
ifr_14_minimo	(1, 1, 0)	(1, 0, 1)	(1, 1, 0)	6
mm_5_maximo	(0, 0, 1)	(1, 1, 1)	(0, 1, 1)	6
ifr_21_maximo	(0, 0, 1)	(1, 1, 1)	(1, 1, 0)	6
dp_10_qtd_negocios	(1, 1, 1)	(1, 1, 0)	(0, 1, 0)	6
dp_10_fechamento	(0, 1, 0)	(0, 1, 1)	(1, 1, 1)	6
dp_10_abertura	(1, 1, 0)	(1, 1, 0)	(1, 0, 1)	6
mm_30_maximo	(1, 0, 1)	(1, 0, 1)	(1, 1, 0)	6
mm_25_medio	(0, 1, 1)	(1, 1, 0)	(0, 1, 1)	6
dp_60_oferta_compra	(1, 1, 0)	(1, 0, 1)	(0, 1, 1)	6
dp_90_qtd_negocios	(1, 1, 1)	(0, 1, 0)	(0, 1, 1)	6
mm_15_abertura	(0, 1, 1)	(0, 1, 0)	(1, 1, 1)	6
mm_15_fechamento	(0, 1, 1)	(0, 1, 1)	(0, 1, 1)	6
mm_25_minimo	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	6
sinal_abertura	(1, 0, 1)	(1, 0, 0)	(1, 1, 1)	6
mm_20_maximo	(1, 1, 1)	(0, 0, 1)	(1, 1, 0)	6
dp_60_volume	(1, 1, 1)	(0, 1, 1)	(0, 0, 1)	6
mm_20_oferta_venda	(1, 1, 0)	(1, 0, 1)	(0, 1, 1)	6
dp_10_volume	(0, 0, 1)	(1, 0, 1)	(1, 0, 1)	5
dp_15_abertura	(1, 1, 0)	(1, 1, 0)	(1, 0, 0)	5
ifr_14_medio	(1, 1, 0)	(1, 1, 0)	(1, 0, 0)	5
ifr_21_minimo	(0, 0, 1)	(1, 1, 0)	(1, 1, 0)	5

Tabela 12 – Relação completa entre a seleção de características, usando algoritmo genético, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
dp_10_medio	(1, 1, 0)	(1, 1, 0)	(0, 0, 1)	5
dp_15_maximo	(1, 0, 1)	(1, 0, 1)	(0, 0, 1)	5
macdhist_minimo	(1, 0, 1)	(1, 1, 1)	(0, 0, 0)	5
macdhist_medio	(1, 0, 1)	(0, 1, 1)	(0, 0, 1)	5
dp_15_oferta_compra	(0, 0, 1)	(0, 1, 0)	(1, 1, 1)	5
dp_90_oferta_compra	(1, 1, 0)	(0, 1, 0)	(1, 1, 0)	5
dp_20_abertura	(1, 1, 0)	(0, 1, 1)	(0, 0, 1)	5
vsdme26_abertura	(1, 0, 1)	(1, 0, 1)	(0, 1, 0)	5
dp_90_fechamento	(0, 1, 1)	(0, 1, 1)	(1, 0, 0)	5
dp_20_fechamento	(0, 1, 0)	(1, 1, 1)	(0, 0, 1)	5
dp_90_medio	(0, 1, 0)	(1, 1, 0)	(0, 1, 1)	5
dp_5_volume	(0, 1, 0)	(0, 1, 0)	(1, 1, 1)	5
dp_25_volume	(1, 1, 1)	(1, 0, 0)	(0, 1, 0)	5
ifr_14_maximo	(0, 1, 0)	(1, 1, 0)	(1, 1, 0)	5
dp_30_abertura	(1, 1, 0)	(1, 0, 1)	(1, 0, 0)	5
macd_fechamento	(1, 1, 0)	(1, 0, 0)	(1, 0, 1)	5
vsdme12_abertura	(0, 0, 0)	(1, 1, 1)	(0, 1, 1)	5
vsdme26_medio	(0, 1, 0)	(1, 1, 1)	(1, 0, 0)	5
dp_30_medio	(1, 1, 0)	(0, 0, 1)	(1, 0, 1)	5
mm_5_abertura	(0, 0, 1)	(0, 1, 1)	(0, 1, 1)	5
mm_30_minimo	(1, 1, 0)	(1, 0, 1)	(1, 0, 0)	5
mm_90_maximo	(1, 0, 0)	(1, 1, 0)	(1, 0, 1)	5
mm_20_minimo	(1, 0, 0)	(1, 1, 1)	(0, 1, 0)	5
mm_10_fechamento	(1, 0, 1)	(1, 1, 1)	(0, 0, 0)	5
mm_60_volume	(0, 1, 0)	(0, 1, 0)	(1, 1, 1)	5
mm_30_medio	(1, 1, 1)	(0, 1, 1)	(0, 0, 0)	5
mm_15_oferta_compra	(1, 0, 1)	(1, 1, 1)	(0, 0, 0)	5
mm_90_qtd_negocios	(1, 1, 1)	(0, 0, 0)	(1, 1, 0)	5
dp_5_abertura	(1, 0, 0)	(1, 0, 0)	(1, 1, 1)	5
dp_5_maximo	(1, 1, 0)	(0, 0, 1)	(1, 1, 0)	5
mm_15_medio	(1, 1, 1)	(0, 1, 0)	(1, 0, 0)	5
mm_10_abertura	(0, 1, 1)	(0, 1, 1)	(0, 0, 1)	5
mm_25_volume	(0, 1, 1)	(1, 0, 0)	(1, 0, 1)	5
mm_30_abertura	(0, 1, 1)	(0, 1, 1)	(0, 0, 1)	5
mm_5_minimo	(0, 1, 1)	(0, 0, 1)	(1, 1, 0)	5

Tabela 12 – Relação completa entre a seleção de características, usando algoritmo genético, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
dp_5_fechamento	(0, 1, 1)	(1, 1, 0)	(0, 0, 1)	5
mm_10_oferta_venda	(0, 0, 0)	(0, 1, 1)	(1, 1, 1)	5
macdslope_abertura	(0, 0, 1)	(1, 0, 0)	(1, 0, 1)	4
macdhist_maximo	(0, 1, 0)	(1, 0, 0)	(1, 1, 0)	4
mm_20_volume	(1, 0, 1)	(0, 1, 0)	(0, 0, 1)	4
dp_90_volume	(1, 1, 0)	(1, 0, 0)	(0, 1, 0)	4
mm_20_fechamento	(1, 0, 1)	(1, 1, 0)	(0, 0, 0)	4
macdslope_medio	(0, 1, 1)	(0, 1, 0)	(0, 0, 1)	4
mm_20_qtd_negocios	(0, 0, 1)	(1, 0, 0)	(0, 1, 1)	4
mm_25_maximo	(1, 0, 1)	(1, 0, 0)	(0, 1, 0)	4
mm_25_fechamento	(1, 0, 1)	(0, 0, 0)	(1, 1, 0)	4
mm_25_qtd_negocios	(1, 0, 0)	(1, 0, 0)	(1, 1, 0)	4
mm_15_maximo	(1, 0, 1)	(1, 0, 0)	(0, 0, 1)	4
dp_5_oferta_venda	(0, 1, 0)	(0, 0, 1)	(1, 1, 0)	4
mm_10_qtd_negocios	(1, 1, 1)	(0, 0, 0)	(0, 0, 1)	4
mm_10_maximo	(1, 1, 1)	(0, 0, 0)	(0, 1, 0)	4
mm_5_medio	(0, 1, 0)	(1, 0, 0)	(0, 1, 1)	4
mm_5_fechamento	(0, 0, 1)	(0, 0, 1)	(1, 1, 0)	4
mm_5_oferta_compra	(1, 1, 0)	(0, 1, 0)	(0, 1, 0)	4
ifr_14_abertura	(1, 1, 1)	(0, 0, 0)	(1, 0, 0)	4
ifr_7_minimo	(1, 0, 0)	(0, 0, 1)	(1, 1, 0)	4
df_medio	(1, 0, 1)	(0, 0, 0)	(1, 0, 1)	4
df_abertura	(0, 0, 0)	(0, 0, 1)	(1, 1, 1)	4
sinal_fechamento	(1, 0, 1)	(0, 1, 0)	(0, 1, 0)	4
vsdme26_maximo	(1, 1, 0)	(0, 1, 0)	(0, 0, 1)	4
vsdme12_medio	(1, 0, 1)	(0, 1, 0)	(0, 1, 0)	4
vsdme12_minimo	(1, 0, 1)	(0, 0, 1)	(0, 1, 0)	4
mm_10_volume	(0, 1, 0)	(1, 1, 0)	(0, 0, 1)	4
sinal_medio	(0, 1, 0)	(1, 0, 0)	(1, 1, 0)	4
sinal_minimo	(1, 0, 0)	(1, 1, 0)	(1, 0, 0)	4
vsdme12_maximo	(0, 0, 1)	(1, 0, 0)	(0, 1, 1)	4
dp_90_maximo	(0, 1, 0)	(1, 1, 1)	(0, 0, 0)	4
dp_20_volume	(0, 0, 1)	(1, 0, 0)	(0, 1, 1)	4
dp_30_maximo	(0, 1, 1)	(0, 1, 0)	(0, 0, 1)	4
mm_60_oferta_compra	(0, 0, 0)	(1, 1, 1)	(1, 0, 0)	4

Tabela 12 – Relação completa entre a seleção de características, usando algoritmo genético, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
mm_60_oferta_venda	(1, 0, 0)	(1, 1, 0)	(0, 0, 1)	4
mm_60_minimo	(0, 1, 0)	(0, 0, 1)	(1, 0, 1)	4
dp_25_fechamento	(0, 0, 1)	(0, 1, 0)	(0, 1, 1)	4
mm_90_minimo	(1, 1, 0)	(0, 0, 1)	(1, 0, 0)	4
dp_15_oferta_venda	(0, 0, 1)	(1, 0, 0)	(1, 1, 0)	4
mm_90_medio	(0, 1, 1)	(1, 0, 0)	(0, 0, 1)	4
dp_15_medio	(1, 0, 1)	(0, 0, 0)	(0, 1, 1)	4
dp_25_oferta_venda	(0, 1, 1)	(1, 0, 0)	(1, 0, 0)	4
mm_30_qtd_negocios	(1, 0, 0)	(0, 1, 0)	(1, 0, 1)	4
dp_15_minimo	(0, 0, 0)	(1, 1, 0)	(1, 1, 0)	4
mm_60_abertura	(1, 0, 0)	(1, 0, 1)	(1, 0, 0)	4
dp_30_minimo	(1, 1, 0)	(0, 1, 0)	(1, 0, 0)	4
dp_30_volume	(1, 0, 1)	(0, 0, 0)	(0, 1, 1)	4
dp_10_minimo	(0, 1, 1)	(1, 1, 0)	(0, 0, 0)	4
dp_5_medio	(0, 0, 0)	(1, 1, 1)	(1, 0, 0)	4
dp_30_oferta_compra	(1, 0, 1)	(1, 0, 0)	(0, 0, 1)	4
dp_10_oferta_compra	(0, 0, 0)	(1, 1, 0)	(0, 1, 1)	4
vsdme26_fechamento	(0, 1, 0)	(1, 0, 0)	(0, 1, 0)	3
vsdme12_fechamento	(0, 0, 0)	(0, 1, 1)	(1, 0, 0)	3
dp_20_minimo	(0, 0, 1)	(0, 0, 1)	(0, 0, 1)	3
dp_5_minimo	(0, 0, 0)	(0, 1, 1)	(1, 0, 0)	3
mm_5_oferta_venda	(1, 0, 1)	(0, 1, 0)	(0, 0, 0)	3
ifr_7_abertura	(0, 0, 0)	(0, 1, 1)	(0, 0, 1)	3
dp_15_fechamento	(0, 0, 0)	(0, 0, 1)	(0, 1, 1)	3
mm_10_minimo	(1, 1, 0)	(0, 0, 1)	(0, 0, 0)	3
df_maximo	(1, 0, 1)	(0, 0, 0)	(0, 1, 0)	3
ifr_7_medio	(1, 0, 0)	(0, 0, 1)	(0, 0, 1)	3
mm_90_oferta_venda	(0, 1, 0)	(1, 0, 0)	(1, 0, 0)	3
dp_60_maximo	(0, 0, 1)	(1, 0, 0)	(0, 0, 1)	3
dp_20_oferta_compra	(0, 0, 1)	(0, 1, 0)	(0, 1, 0)	3
dp_60_abertura	(0, 1, 0)	(0, 0, 1)	(0, 0, 1)	3
dp_20_qtd_negocios	(0, 0, 0)	(1, 0, 0)	(1, 1, 0)	3
mm_60_maximo	(0, 1, 0)	(0, 1, 1)	(0, 0, 0)	3
dp_60_medio	(0, 0, 1)	(0, 0, 0)	(1, 0, 1)	3
mm_30_oferta_compra	(0, 0, 1)	(0, 0, 0)	(0, 1, 1)	3

Tabela 12 – Relação completa entre a seleção de características, usando algoritmo genético, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
mm_25_oferta_venda	(0, 1, 1)	(1, 0, 0)	(0, 0, 0)	3
mm_25_oferta_compra	(1, 0, 0)	(0, 0, 0)	(1, 1, 0)	3
mm_30_oferta_venda	(1, 0, 0)	(0, 0, 1)	(0, 0, 1)	3
mm_30_volume	(0, 1, 0)	(0, 1, 1)	(0, 0, 0)	3
macdhist_fechamento	(0, 0, 0)	(0, 1, 1)	(1, 0, 0)	3
dp_15_volume	(0, 0, 1)	(0, 0, 0)	(1, 1, 0)	3
dp_25_medio	(0, 0, 0)	(1, 0, 1)	(1, 0, 0)	3
mm_15_minimo	(1, 0, 1)	(0, 0, 0)	(0, 0, 1)	3
macdslope_maximo	(0, 1, 0)	(0, 0, 1)	(0, 0, 1)	3
mm_90_abertura	(0, 1, 0)	(1, 0, 0)	(0, 0, 0)	2
macd_medio	(0, 0, 0)	(1, 1, 0)	(0, 0, 0)	2
dp_20_oferta_venda	(0, 0, 1)	(0, 0, 0)	(1, 0, 0)	2
mm_15_oferta_venda	(0, 0, 0)	(1, 0, 0)	(1, 0, 0)	2
ifr_21_fechamento	(0, 0, 1)	(0, 1, 0)	(0, 0, 0)	2
mm_15_qtd_negocios	(0, 0, 1)	(0, 0, 1)	(0, 0, 0)	2
sinal_maximo	(0, 1, 0)	(0, 1, 0)	(0, 0, 0)	2
dp_30_oferta_venda	(1, 0, 0)	(0, 0, 1)	(0, 0, 0)	2
ifr_7_fechamento	(0, 0, 0)	(1, 0, 0)	(0, 0, 1)	2
ifr_7_maximo	(0, 1, 0)	(0, 1, 0)	(0, 0, 0)	2
dp_10_oferta_venda	(0, 1, 0)	(0, 0, 1)	(0, 0, 0)	2
dp_25_maximo	(0, 0, 0)	(1, 0, 0)	(0, 0, 0)	1
mm_60_fechamento	(0, 0, 1)	(0, 0, 0)	(0, 0, 0)	1
dp_5_oferta_compra	(0, 0, 1)	(0, 0, 0)	(0, 0, 0)	1
mm_5_volume	(0, 0, 1)	(0, 0, 0)	(0, 0, 0)	1
dp_90_minimo	(1, 0, 0)	(0, 0, 0)	(0, 0, 0)	1
mm_10_medio	(0, 0, 0)	(0, 1, 0)	(0, 0, 0)	1
macd_abertura	(0, 0, 0)	(0, 0, 0)	(1, 0, 0)	1
macdhist_abertura	(0, 0, 0)	(0, 0, 0)	(0, 0, 0)	0
macd_maximo	(0, 0, 0)	(0, 0, 0)	(0, 0, 0)	0
dp_10_maximo	(0, 0, 0)	(0, 0, 0)	(0, 0, 0)	0

(Concluído)

Fonte: Autoria própria.

APÊNDICE C – Tabela completa com os indicadores técnicos selecionados, usando *Step-Forward* com hiperparâmetros ajustados

Tabela 13 – Relação completa entre a seleção de características, usando *Step-Forward* com hiperparâmetros ajustados, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
mm_30_abertura	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	9
macdslope_fechamento	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	9
macdslope_maximo	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	9
dp_15_fechamento	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	9
macdslope_minimo	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	9
vsdme12_minimo	(1, 1, 1)	(1, 1, 1)	(1, 1, 1)	9
dp_15_volume	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	8
dp_5_volume	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	8
mm_25_abertura	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	8
mm_30_maximo	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	8
mm_30_volume	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	8
vsdme26_fechamento	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	8
mm_60_abertura	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
mm_90_volume	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	8
dp_5_oferta_venda	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	8
macdslope_medio	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
dp_10_abertura	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
mm_20_abertura	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
dp_10_volume	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	8
macdslope_abertura	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
dp_20_minimo	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
dp_30_minimo	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
dp_30_volume	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	8
macd_fechamento	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
dp_90_volume	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	8
mm_20_maximo	(1, 1, 1)	(1, 1, 0)	(1, 1, 1)	8

Tabela 13 – Relação completa entre a seleção de características, usando *Step-Forward* com hiperparâmetros ajustados, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
dp_90_medio	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	8
df_minimo	(1, 1, 0)	(1, 1, 1)	(1, 1, 1)	8
mm_15_minimo	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
mm_10_volume	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	8
mm_5_fechamento	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
mm_15_volume	(1, 0, 1)	(1, 1, 1)	(1, 1, 1)	8
mm_15_medio	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
mm_15_fechamento	(1, 1, 1)	(1, 0, 1)	(1, 1, 1)	8
dp_25_medio	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
mm_90_medio	(1, 0, 0)	(1, 1, 1)	(1, 1, 1)	7
dp_5_minimo	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
df_medio	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
vsdme12_abertura	(1, 1, 1)	(1, 0, 1)	(1, 1, 0)	7
mm_90_minimo	(1, 0, 1)	(1, 0, 1)	(1, 1, 1)	7
mm_15_abertura	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
dp_5_abertura	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
mm_90_abertura	(1, 1, 0)	(1, 1, 0)	(1, 1, 1)	7
dp_5_maximo	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
macdhist_fechamento	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
macdhist_maximo	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
dp_5_fechamento	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
mm_60_volume	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	7
dp_20_volume	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	7
senal_maximo	(1, 1, 1)	(1, 0, 1)	(1, 1, 0)	7
dp_10_minimo	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
dp_20_medio	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
dp_20_maximo	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
dp_20_abertura	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	7
ifr_7_minimo	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	7
mm_10_minimo	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
macdhist_medio	(1, 1, 1)	(1, 0, 1)	(1, 1, 0)	7
dp_15_maximo	(0, 1, 0)	(1, 1, 1)	(1, 1, 1)	7
mm_5_volume	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	7
dp_25_fechamento	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
ifr_21_abertura	(1, 0, 1)	(1, 1, 1)	(1, 1, 0)	7

Tabela 13 – Relação completa entre a seleção de características, usando *Step-Forward* com hiperparâmetros ajustados, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
mm_25_volume	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	7
ifr_21_maximo	(1, 1, 1)	(0, 1, 1)	(1, 0, 1)	7
dp_60_maximo	(1, 0, 0)	(1, 1, 1)	(1, 1, 1)	7
df_fechamento	(1, 0, 1)	(1, 1, 0)	(1, 1, 1)	7
mm_25_oferta_compra	(1, 0, 1)	(1, 0, 1)	(1, 1, 1)	7
mm_20_volume	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	7
macdhist_abertura	(1, 1, 1)	(1, 0, 1)	(1, 1, 0)	7
macd_minimo	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
macd_abertura	(1, 0, 1)	(1, 0, 1)	(1, 1, 1)	7
mm_15_oferta_compra	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
dp_30_medio	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
mm_20_fechamento	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
vsdme26_maximo	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	7
mm_20_medio	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
mm_15_maximo	(0, 1, 0)	(1, 1, 1)	(1, 1, 1)	7
dp_60_volume	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	7
mm_60_minimo	(0, 1, 1)	(1, 0, 1)	(1, 1, 1)	7
dp_25_qtd_negocios	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	7
dp_25_volume	(0, 0, 1)	(1, 1, 1)	(1, 1, 1)	7
mm_25_minimo	(1, 1, 0)	(1, 0, 1)	(1, 1, 1)	7
dp_20_fechamento	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	6
dp_60_oferta_venda	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	6
mm_10_maximo	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	6
mm_5_medio	(0, 1, 1)	(1, 0, 0)	(1, 1, 1)	6
macd_maximo	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	6
dp_20_oferta_compra	(1, 1, 0)	(1, 0, 1)	(1, 1, 0)	6
dp_30_oferta_venda	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	6
dp_25_abertura	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	6
macd_medio	(0, 0, 0)	(1, 1, 1)	(1, 1, 1)	6
dp_30_maximo	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	6
dp_25_minimo	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	6
dp_30_abertura	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	6
dp_25_oferta_compra	(1, 0, 1)	(1, 0, 1)	(1, 0, 1)	6
ifr_7_maximo	(1, 0, 1)	(1, 1, 0)	(0, 1, 1)	6
mm_60_fechamento	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	6

Tabela 13 – Relação completa entre a seleção de características, usando *Step-Forward* com hiperparâmetros ajustados, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
mm_30_minimo	(1, 0, 0)	(1, 1, 0)	(1, 1, 1)	6
mm_60_oferta_compra	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	6
dp_15_medio	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	6
mm_60_medio	(0, 0, 0)	(1, 1, 1)	(1, 1, 1)	6
mm_30_oferta_compra	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	6
mm_30_fechamento	(1, 0, 0)	(0, 1, 1)	(1, 1, 1)	6
vsdme26_minimo	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	6
mm_25_oferta_venda	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	6
vsdme12_medio	(1, 1, 0)	(1, 0, 1)	(1, 1, 0)	6
mm_25_fechamento	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	6
mm_25_maximo	(1, 1, 1)	(1, 0, 0)	(1, 0, 1)	6
mm_15_oferta_venda	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	6
mm_20_oferta_venda	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	6
df_maximo	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	6
mm_20_minimo	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	6
mm_60_oferta_venda	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	6
mm_90_fechamento	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	6
dp_10_fechamento	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	6
dp_15_minimo	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	6
dp_5_medio	(1, 0, 0)	(1, 0, 1)	(1, 1, 1)	6
dp_15_abertura	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	6
senal_medio	(1, 1, 0)	(1, 0, 0)	(1, 1, 1)	6
senal_minimo	(1, 0, 0)	(1, 1, 1)	(1, 1, 0)	6
mm_10_fechamento	(0, 1, 0)	(1, 0, 1)	(1, 1, 1)	6
vsdme12_maximo	(0, 0, 1)	(1, 0, 1)	(1, 1, 1)	6
senal_abertura	(1, 0, 1)	(1, 0, 0)	(1, 1, 1)	6
ifr_21_fechamento	(0, 1, 1)	(0, 0, 1)	(1, 1, 0)	5
dp_90_fechamento	(1, 0, 0)	(1, 0, 1)	(1, 1, 0)	5
ifr_21_minimo	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	5
dp_90_qtd_negocios	(0, 0, 1)	(0, 0, 1)	(1, 1, 1)	5
dp_90_maximo	(1, 0, 0)	(1, 0, 1)	(1, 1, 0)	5
df_abertura	(1, 0, 0)	(1, 0, 1)	(1, 1, 0)	5
senal_fechamento	(1, 1, 0)	(1, 0, 0)	(1, 1, 0)	5
vsdme26_medio	(0, 1, 0)	(1, 0, 1)	(1, 1, 0)	5
macdhist_minimo	(1, 0, 0)	(1, 0, 0)	(1, 1, 1)	5

Tabela 13 – Relação completa entre a seleção de características, usando *Step-Forward* com hiperparâmetros ajustados, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
ifr_7_fechamento	(1, 1, 1)	(0, 0, 1)	(1, 0, 0)	5
vsdme26_abertura	(0, 0, 0)	(1, 1, 0)	(1, 1, 1)	5
vsdme12_fechamento	(1, 0, 0)	(1, 1, 0)	(1, 1, 0)	5
ifr_14_medio	(0, 0, 1)	(1, 1, 0)	(1, 0, 1)	5
mm_5_abertura	(0, 0, 0)	(1, 1, 0)	(1, 1, 1)	5
dp_90_abertura	(0, 0, 1)	(0, 0, 1)	(1, 1, 1)	5
mm_10_medio	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	5
mm_90_oferta_compra	(1, 0, 0)	(0, 0, 1)	(1, 1, 1)	5
mm_30_oferta_venda	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	5
mm_30_medio	(1, 0, 0)	(1, 0, 0)	(1, 1, 1)	5
mm_25_medio	(1, 0, 0)	(1, 0, 0)	(1, 1, 1)	5
mm_20_qtd_negocios	(0, 0, 1)	(1, 0, 1)	(1, 1, 0)	5
dp_10_maximo	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	5
dp_10_medio	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	5
mm_20_oferta_compra	(1, 0, 0)	(0, 0, 1)	(1, 1, 1)	5
dp_10_qtd_negocios	(0, 0, 1)	(0, 1, 1)	(1, 1, 0)	5
dp_15_oferta_compra	(0, 1, 0)	(1, 0, 1)	(1, 1, 0)	5
mm_10_oferta_venda	(0, 0, 1)	(1, 0, 0)	(1, 1, 1)	5
mm_10_oferta_compra	(1, 0, 0)	(1, 0, 1)	(1, 1, 0)	5
dp_20_oferta_venda	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	5
dp_60_abertura	(0, 0, 0)	(1, 1, 1)	(1, 1, 0)	5
dp_60_minimo	(0, 0, 1)	(1, 0, 1)	(1, 1, 0)	5
dp_60_qtd_negocios	(0, 0, 1)	(0, 1, 1)	(0, 1, 1)	5
dp_60_oferta_compra	(0, 0, 1)	(1, 0, 1)	(1, 1, 0)	5
mm_5_minimo	(0, 1, 0)	(1, 0, 0)	(1, 1, 1)	5
mm_5_oferta_compra	(0, 0, 1)	(0, 0, 1)	(1, 1, 1)	5
dp_60_fechamento	(0, 0, 0)	(1, 1, 1)	(1, 1, 0)	5
mm_5_oferta_venda	(0, 0, 1)	(1, 0, 0)	(1, 1, 1)	5
mm_30_qtd_negocios	(0, 0, 1)	(1, 0, 1)	(0, 1, 1)	5
mm_10_abertura	(0, 0, 0)	(1, 0, 1)	(1, 1, 1)	5
dp_30_oferta_compra	(0, 1, 0)	(1, 0, 1)	(1, 1, 0)	5
dp_25_maximo	(0, 1, 0)	(1, 0, 0)	(1, 1, 1)	5
mm_60_maximo	(0, 0, 0)	(0, 0, 1)	(1, 1, 1)	4
mm_10_qtd_negocios	(0, 0, 1)	(0, 0, 1)	(1, 1, 0)	4
ifr_14_maximo	(1, 0, 0)	(1, 0, 0)	(1, 1, 0)	4

Tabela 13 – Relação completa entre a seleção de características, usando *Step-Forward* com hiperparâmetros ajustados, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3	ITSA4	PETR4	
Indicadores	(5, 15, 30)	(5, 15, 30)	(5, 15, 30)	Total
ifr_14_fechamento	(1, 0, 1)	(0, 0, 1)	(1, 0, 0)	4
ifr_7_medio	(0, 0, 1)	(1, 0, 0)	(1, 1, 0)	4
mm_90_oferta_venda	(1, 0, 0)	(0, 0, 0)	(1, 1, 1)	4
mm_5_maximo	(0, 0, 0)	(1, 0, 0)	(1, 1, 1)	4
dp_25_oferta_venda	(0, 0, 0)	(1, 0, 1)	(1, 1, 0)	4
dp_90_oferta_compra	(0, 1, 0)	(1, 0, 0)	(1, 1, 0)	4
dp_90_oferta_venda	(0, 0, 1)	(1, 0, 0)	(1, 1, 0)	4
dp_60_medio	(0, 0, 0)	(1, 0, 1)	(1, 1, 0)	4
dp_5_oferta_compra	(1, 0, 0)	(1, 0, 0)	(1, 1, 0)	4
dp_5_qtd_negocios	(0, 0, 1)	(0, 0, 1)	(1, 1, 0)	4
dp_10_oferta_compra	(0, 0, 0)	(1, 0, 0)	(1, 1, 1)	4
dp_10_oferta_venda	(0, 0, 0)	(1, 0, 0)	(1, 1, 1)	4
dp_15_oferta_venda	(0, 0, 0)	(1, 0, 1)	(1, 1, 0)	4
mm_90_maximo	(0, 0, 0)	(0, 0, 1)	(1, 1, 1)	4
dp_15_qtd_negocios	(0, 0, 1)	(0, 0, 1)	(1, 1, 0)	4
dp_30_fechamento	(0, 0, 0)	(1, 0, 0)	(1, 1, 1)	4
dp_30_qtd_negocios	(0, 0, 0)	(0, 0, 1)	(1, 1, 0)	3
ifr_14_minimo	(0, 1, 1)	(0, 0, 1)	(0, 0, 0)	3
mm_60_qtd_negocios	(0, 0, 1)	(0, 0, 1)	(0, 1, 0)	3
ifr_14_abertura	(0, 1, 0)	(0, 0, 1)	(0, 1, 0)	3
dp_20_qtd_negocios	(0, 0, 0)	(0, 0, 0)	(1, 1, 1)	3
ifr_7_abertura	(0, 0, 1)	(0, 1, 0)	(0, 1, 0)	3
mm_15_qtd_negocios	(0, 0, 1)	(0, 1, 1)	(0, 0, 0)	3
mm_25_qtd_negocios	(0, 0, 1)	(0, 0, 1)	(0, 1, 0)	3
mm_90_qtd_negocios	(0, 0, 1)	(0, 0, 1)	(0, 1, 0)	3
ifr_21_medio	(0, 0, 0)	(0, 0, 1)	(1, 1, 0)	3
dp_90_minimo	(0, 0, 0)	(1, 0, 0)	(1, 0, 0)	2
mm_5_qtd_negocios	(0, 0, 0)	(0, 0, 0)	(0, 1, 0)	1

(Concluído)

Fonte: Autoria própria.

APÊNDICE D – Tabela completa com os indicadores técnicos selecionados, usando *Step-Forward* sem ajuste de hiperparâmetro

Tabela 14 – Relação completa entre a seleção de características, usando *Step-Forward* sem ajuste de hiperparâmetros, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Indicadores	VALE3 (5)			Total
	Linear	Sigmoid	RBF	
mm_30_oferta_compra	1	1	1	3
mm_15_oferta_venda	1	1	1	3
mm_90_minimo	1	1	1	3
mm_25_maximo	1	1	1	3
mm_15_minimo	1	1	1	3
vsdme26_maximo	1	0	1	2
vsdme26_minimo	1	0	1	2
vsdme26_medio	1	0	1	2
mm_25_qtd_negocios	1	1	0	2
mm_25_oferta_compra	1	0	1	2
mm_25_volume	1	1	0	2
dp_30_qtd_negocios	1	1	0	2
dp_10_qtd_negocios	1	1	0	2
macd_maximo	1	1	0	2
mm_25_minimo	1	0	1	2
df_minimo	1	1	0	2
vsdme26_fechamento	1	0	1	2
mm_5_abertura	1	1	0	2
macdslope_abertura	1	1	0	2
vsdme12_medio	1	1	0	2
macdhist_abertura	1	1	0	2
mm_30_qtd_negocios	1	1	0	2
macdhist_fechamento	1	1	0	2
vsdme12_fechamento	1	1	0	2
dp_15_qtd_negocios	1	1	0	2
dp_60_qtd_negocios	1	1	0	2

Tabela 14 – Relação completa entre a seleção de características, usando *Step-Forward* sem ajuste de hiperparâmetros, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Indicadores	VALE3 (5)			Total
	Linear	Sigmoid	RBF	
sinal_minimo	1	1	0	2
sinal_maximo	1	1	0	2
sinal_fechamento	1	1	0	2
sinal_abertura	1	1	0	2
mm_60_qtd_negocios	1	1	0	2
mm_90_qtd_negocios	1	1	0	2
mm_20_qtd_negocios	1	1	0	2
macdslope_fechamento	1	1	0	2
ifr_7_abertura	1	1	0	2
dp_5_qtd_negocios	1	1	0	2
dp_25_qtd_negocios	1	1	0	2
ifr_21_maximo	1	1	0	2
mm_5_oferta_compra	1	1	0	2
mm_5_oferta_venda	1	1	0	2
mm_5_volume	1	1	0	2
mm_5_qtd_negocios	1	1	0	2
mm_10_abertura	1	1	0	2
mm_10_maximo	1	0	1	2
mm_10_minimo	1	0	1	2
ifr_21_abertura	1	1	0	2
ifr_14_medio	1	1	0	2
mm_10_oferta_compra	1	0	1	2
mm_20_oferta_compra	1	0	1	2
dp_90_qtd_negocios	1	1	0	2
mm_10_qtd_negocios	1	1	0	2
mm_15_maximo	1	0	1	2
dp_20_qtd_negocios	1	1	0	2
ifr_14_abertura	1	1	0	2
mm_15_oferta_compra	1	1	0	2
ifr_7_minimo	1	1	0	2
mm_15_qtd_negocios	1	1	0	2
mm_15_abertura	1	0	1	2
mm_20_maximo	1	0	1	2
ifr_7_fechamento	1	1	0	2
mm_20_fechamento	1	0	1	2

Tabela 14 – Relação completa entre a seleção de características, usando *Step-Forward* sem ajuste de hiperparâmetros, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Indicadores	VALE3 (5)			Total
	Linear	Sigmoid	RBF	
mm_20_medio	1	0	1	2
dp_60_volume	1	0	0	1
dp_60_oferta_venda	1	0	0	1
dp_90_minimo	1	0	0	1
dp_90_medio	1	0	0	1
dp_90_abertura	1	0	0	1
dp_90_maximo	1	0	0	1
dp_30_volume	1	0	0	1
dp_60_oferta_compra	1	0	0	1
dp_60_fechamento	1	0	0	1
dp_60_medio	1	0	0	1
dp_60_minimo	1	0	0	1
dp_60_maximo	1	0	0	1
dp_60_abertura	1	0	0	1
dp_90_oferta_compra	1	0	0	1
dp_30_oferta_venda	1	0	0	1
dp_30_oferta_compra	1	0	0	1
dp_30_fechamento	1	0	0	1
dp_30_medio	1	0	0	1
dp_30_minimo	1	0	0	1
dp_30_maximo	1	0	0	1
dp_30_abertura	1	0	0	1
dp_90_fechamento	1	0	0	1
vsdme12_abertura	1	0	0	1
dp_90_oferta_venda	1	0	0	1
dp_90_volume	1	0	0	1
ifr_21_minimo	1	0	0	1
ifr_21_fechamento	1	0	0	1
ifr_14_minimo	1	0	0	1
ifr_14_maximo	1	0	0	1
ifr_14_fechamento	1	0	0	1
ifr_7_maximo	1	0	0	1
df_medio	1	0	0	1
df_maximo	1	0	0	1
df_fechamento	1	0	0	1

Tabela 14 – Relação completa entre a seleção de características, usando *Step-Forward* sem ajuste de hiperparâmetros, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Indicadores	VALE3 (5)			Total
	Linear	Sigmoid	RBF	
df_abertura	1	0	0	1
vsdme26_abertura	1	0	0	1
vsdme12_minimo	1	0	0	1
vsdme12_maximo	1	0	0	1
dp_25_oferta_venda	1	0	0	1
sinal_medio	1	0	0	1
macdslope_medio	1	0	0	1
macdslope_minimo	1	0	0	1
macdslope_maximo	1	0	0	1
macdhist_medio	1	0	0	1
macdhist_minimo	1	0	0	1
macdhist_maximo	1	0	0	1
macd_medio	1	0	0	1
macd_minimo	1	0	0	1
macd_fechamento	1	0	0	1
macd_abertura	1	0	0	1
dp_25_volume	1	0	0	1
dp_15_volume	1	0	0	1
dp_25_oferta_compra	1	0	0	1
mm_60_minimo	1	0	0	1
mm_30_minimo	1	0	0	1
mm_30_medio	1	0	0	1
mm_30_fechamento	1	0	0	1
mm_30_oferta_venda	1	0	0	1
mm_30_volume	1	0	0	1
mm_60_abertura	1	0	0	1
mm_60_maximo	1	0	0	1
mm_60_medio	1	0	0	1
mm_30_abertura	1	0	0	1
mm_60_fechamento	1	0	0	1
mm_60_oferta_compra	1	0	0	1
mm_60_oferta_venda	1	0	0	1
mm_60_volume	1	0	0	1
mm_90_abertura	1	0	0	1
mm_90_maximo	1	0	0	1

Tabela 14 – Relação completa entre a seleção de características, usando *Step-Forward* sem ajuste de hiperparâmetros, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

Indicadores	VALE3 (5)			Total
	Linear	Sigmoid	RBF	
mm_90_medio	1	0	0	1
mm_30_maximo	1	0	0	1
mm_25_oferta_venda	1	0	0	1
dp_25_fechamento	1	0	0	1
mm_15_medio	1	0	0	1
mm_5_minimo	1	0	0	1
mm_5_medio	1	0	0	1
mm_5_fechamento	1	0	0	1
mm_10_medio	1	0	0	1
mm_10_fechamento	1	0	0	1
mm_10_oferta_venda	1	0	0	1
mm_10_volume	1	0	0	1
mm_15_fechamento	1	0	0	1
mm_25_fechamento	1	0	0	1
mm_15_volume	1	0	0	1
mm_20_abertura	1	0	0	1
mm_20_minimo	1	0	0	1
mm_20_oferta_venda	1	0	0	1
mm_20_volume	1	0	0	1
mm_25_abertura	1	0	0	1
mm_25_medio	1	0	0	1
mm_90_fechamento	1	0	0	1
mm_90_oferta_compra	1	0	0	1
mm_90_oferta_venda	1	0	0	1
dp_20_medio	1	0	0	1
dp_15_fechamento	1	0	0	1
dp_15_oferta_compra	1	0	0	1
dp_15_oferta_venda	1	0	0	1
mm_5_maximo	1	0	0	1
dp_20_abertura	1	0	0	1
dp_20_maximo	1	0	0	1
dp_20_minimo	1	0	0	1
dp_20_fechamento	1	0	0	1
mm_90_volume	1	0	0	1
dp_20_oferta_compra	1	0	0	1

Tabela 14 – Relação completa entre a seleção de características, usando *Step-Forward* sem ajuste de hiperparâmetros, e os indicadores escolhidos, com ordenação começando do indicador mais escolhido para o menos escolhido.

(Continua)

	VALE3 (5)			
Indicadores	Linear	Sigmoid	RBF	Total
dp_20_oferta_venda	1	0	0	1
dp_20_volume	1	0	0	1
dp_25_abertura	1	0	0	1
dp_25_maximo	1	0	0	1
dp_25_minimo	1	0	0	1
dp_25_medio	1	0	0	1
dp_15_medio	1	0	0	1
dp_15_minimo	1	0	0	1
dp_15_maximo	1	0	0	1
dp_15_abertura	1	0	0	1
dp_5_abertura	1	0	0	1
dp_5_maximo	1	0	0	1
dp_5_minimo	1	0	0	1
dp_5_medio	1	0	0	1
dp_5_fechamento	1	0	0	1
dp_5_oferta_compra	1	0	0	1
dp_5_oferta_venda	1	0	0	1
dp_5_volume	1	0	0	1
dp_10_abertura	1	0	0	1
dp_10_maximo	1	0	0	1
dp_10_minimo	1	0	0	1
dp_10_medio	1	0	0	1
dp_10_fechamento	1	0	0	1
dp_10_oferta_compra	1	0	0	1
dp_10_oferta_venda	1	0	0	1
dp_10_volume	1	0	0	1
ifr_21_medio	1	0	0	1
ifr_7_medio	0	0	0	0

(Concluído)

Fonte: Autoria própria.

Anexos

ANEXO A – Tabela ações do índice IBrX-50, extraídas no dia 16 de fevereiro de 2022

Tabela 15 – Ações listadas no índice IBrX-50.

(Continua)

Ação	Empresa	Percentual de participação no índice
VALE3	VALE	22,695
PETR4	PETROBRAS	7,744
PETR3	PETROBRAS	6,827
ITUB4	ITAUUNIBANCO	6,669
BBDC4	BRADESCO	5,191
B3SA3	B3	4,624
ABEV3	AMBEV S/A	3,501
HAPV3	HAPVIDA	2,942
ITSA4	ITAUSA	2,624
JBSS3	JBS	2,607
BBAS3	BRASIL	2,606
WEGE3	WEG	2,55
SUZB3	SUZANO S.A.	2,173
RENT3	LOCALIZA	1,879
BPAC11	BTGP BANCO	1,684
GGBR4	GERDAU	1,586
VBBR3	VIBRA	1,396
LREN3	LOJAS RENNER	1,386
CSAN3	COSAN	1,361
EQTL3	EQUATORIAL	1,297
PRIO3	PETRORIO	1,128
BRFS3	BRF SA	1,073
AMER3	AMERICANAS	1,07
RAIL3	RUMO S.A.	1,057
NTCO3	GRUPO NATURA	1,04
MGLU3	MAGAZ LUIZA	1,034
KLBN11	KLABIN S/A	0,98
CSNA3	SID NACIONAL	0,886

Tabela 15 – Ações listadas no índice IBrX-50.

Ação	Empresa	Percentual de participação no índice
BIDI11	BANCO INTER	0,849
TOTS3	TOTVS	0,82
EMBR3	EMBRAER	0,758
BRKM5	BRASKEM	0,713
ELET3	ELETROBRAS	0,664
AZUL4	AZUL	0,501
BRML3	BR MALLS PAR	0,426
USIM5	USIMINAS	0,419
GOAU4	GERDAU MET	0,415
MRFG3	MARFRIG	0,405
BRAP4	BRADESPAR	0,393
VIIA3	VIA	0,343
MULT3	MULTIPLAN	0,322
LWSA3	LOCAWEB	0,251
CYRE3	CYRELA REALT	0,244
COGN3	COGNA ON	0,232
IRBR3	IRBBRASIL RE	0,215
GOLL4	GOL	0,171
CVCB3	CVC BRASIL	0,167
CASH3	MELIUZ	0,082
(Concluído)		

Fonte: Extraído de ([B3, 2022](#)). Acesso em: 16 de fevereiro de 2022.